Ders 12 Çalışma Özeti

Ders 12 Çalışma Özeti

Genel Konular

- Dersin tarihi 4 Haziran 2021 Cuma. Ders Zoom üzerinden yapıldı.
  - Asıl ders yaklaşık 00:07'de başlar. Kaydın başı bekleme kısmıdır.
  - Ders iki saat anlatım olarak yapıldı. Son saatte klasik bir quiz vardı (50 dakika). Cache konusu bu quiz'e dahil değildi.
- Önceki konulara dair öğrenci soruları
  - Interface sorusu (soru 3): adres hattı numarasındaki bir hata düzeltildi.
  - Seri iletişim çerçevesi: hoca önceki derste çerçeveyi yanlışlıkla "stop" ile başlattığını söyledi ve düzeltti.
- Cache memory (önbellek)
  - Bellek hiyerarşisi (memory hierarchy): register, L1 cache, L2 cache, ana bellek (DRAM), disk.
  - Yerellik ilkesi (principle of locality): zamansal (temporal) ve uzamsal (spatial) yerellik.
  - İşlemci ile DRAM arasındaki hız farkı (processor-memory gap).
  - Direct mapped cache: adresin tag, index, word offset ve byte offset alanlarına bölünmesi.
  - Adım adım direct mapped cache örneği: 0x14, 0x1C, 0x34, 0x8014 adreslerinin okunması.
  - Valid bit, cache hit, cache miss ve blok yerine koyma (replacement).
  - Ortalama erişim süresi (average access time) ve iki seviyeli cache örneği.
  - Yerine koyma algoritmaları: LRU, FIFO, random, optimal.
  - Yazma politikaları: write-through ve write-back, dirty bit.
  - Bitiş örneği: 32 bit adres, 64 bit veri yolu, 2 MB cache, 32 byte line için fully associative, direct mapped ve 2-way set associative alan hesapları.

Hocanın Özellikle Vurguladığı Kısımlar

- Dersin son dört haftası en önemli konuları içerir.
  - Giriş/çıkış ve iletişim, cache memory ve virtual memory finalde ağırlıklı sorulacak.
  - Bu konular Mikroişlemciler dersinde de işinize yarayacak.
- Cache konusunda ezber gerekmez.
  - Matematiği dikkatli takip ederseniz her soruyu çözebilirsiniz.
- Word, veri yolu genişliği kadardır.
  - 32 bit veri yolunda 1 word = 4 byte. 64 bit veri yolunda 1 word = 8 byte.
  - 8086'da öğrendiğiniz "1 word = 16 bit" bilgisini buraya taşımayın.
- Cache kapasitesi yalnız veri (data) kapasitesidir.
  - Tag, valid ve dirty bitleri kapasite hesabına katılmaz.
- Cache'te adresin tamamı değil, yalnız tag alanı saklanır.
  - Index ve offset alanları satırın yerinden ve satır içindeki konumdan zaten bellidir.
- Hit için iki koşul gerekir: valid bit 1 olmalı ve tag'ler eşleşmeli.
  - Valid bit 1 olduğu hâlde tag tutmazsa sonuç miss'tir.
- Direct mapped cache'te seçim yoktur.
  - Index hangi satırı gösteriyorsa blok oraya yazılır. Yerine koyma politikası yalnız associative ve set associative yapılarda anlamlıdır.
- Seri iletişimde çerçeve her zaman start biti (lojik 0) ile başlar.
  - Stop biti lojik 1'dir. Stop bitlerinin sayısı 1, 1.5 veya 2 olabilir.

Kısa Tekrar Notları

- Bellek hiyerarşisinde işlemciden uzaklaştıkça kapasite artar, hız düşer, byte başına maliyet azalır.
- Zamansal yerellik: aynı adrese yakın zamanda tekrar erişilir (döngüler, alt programlar).
- Uzamsal yerellik: yakın adreslere yakın zamanda erişilir (diziler, ardışık komutlar).
  - Cache'e tek byte değil blok taşınmasının sebebi uzamsal yerelliktir.
- Direct mapped adres bölümü (yüksek bitten düşüğe): tag | index | word offset | byte offset.
  - Satır sayısı $= \dfrac{\text{cache kapasitesi}}{\text{blok boyutu}}$, index bit sayısı $= \log_2(\text{satır sayısı})$.
  - Byte offset $= \log_2(\text{word içindeki byte sayısı})$, word offset $= \log_2(\text{bloktaki word sayısı})$.
  - Tag = adres genişliği − index − offset.
- Ortalama erişim süresi: $T_a = H\,T_c + (1-H)(T_c + T_m) = T_c + (1-H)\,T_m$.
- İki seviyeli cache: L1 miss cezası $= T_{L2} + m_{L2} \cdot T_{mem}$; AMAT $= T_{L1} + m_{L1} \cdot (\text{L1 miss cezası})$.
- Write-through: her yazmada cache ve ana bellek birlikte güncellenir; bellek her zaman tutarlıdır.
- Write-back: yalnız cache güncellenir, dirty bit 1 yapılır; blok çıkarılırken dirty ise ana belleğe yazılır.
- Okuma işlemleri toplam erişimlerin yaklaşık %75'idir, yazma %25'idir (dersteki istatistik).

Detaylı Açıklamalar

Önceki derslere dair düzeltmeler

- Interface sorusu (soru 3):
  - 8 bitlik adres yolu var. En yüksek iki bit (A7, A6) bütün interface'lerin register select uçlarına ortak bağlanır.
  - Kalan altı bit (A0–A5) altı interface'in chip select uçlarına tek tek bağlanır: A0 birinci interface'e, A5 altıncı interface'e.
  - Kitaptaki soru metninde "address line 4" yazıyordu. Öğrenci bunun 5 olması gerektiğini gösterdi, hoca onayladı: kitap da hata yapabilir.
  - Her interface'in 4 iç register'ı olduğu için her interface I/O alanında 4 adres kaplar. Soruda bu adresler isteniyor.
- Asenkron seri çerçeve:
  - Çerçeve bir start biti (lojik 0) ile başlar, veri bitleri gelir, bir veya daha fazla stop biti (lojik 1) ile biter.

Bellek hiyerarşisi

- CPU yongasının içinde register'lar ve L1 cache bulunur. Slayttaki eski mimaride L2 cache anakart üzerindedir.
- Slayttaki örnek değerler (eski bir mimari, mertebeler önemli):
  - Register erişimi yaklaşık 1.4 ns, L1 yaklaşık 4.2 ns, L2 bunun yaklaşık 4 katı.
  - Ana bellek L2'den yaklaşık 5 kat yavaş. Disk en yavaş ve en ucuz seviye.
- İşlemci-bellek hız farkı:
  - Derste anlatılan: işlemci hızı yılda yaklaşık %60 artarken DRAM erişim hızı yılda yalnız yaklaşık %9 iyileşiyor. Aradaki açık her yıl büyüyor.
  - Çözümlerden biri veri yolunu genişletmek (16 → 32 → 64 bit). Diğeri cache kullanmak.

Direct mapped cache: alan hesabı

- Örnek: 32 bit mimari (adres ve veri yolu 32 bit), 16 KB veri kapasiteli direct mapped cache, blok = 4 word.
  - 1 word = 4 byte, 1 blok = 16 byte $= 2^4$ byte.
  - Satır sayısı $= 2^{14}/2^4 = 2^{10}$, index 10 bit.
  - Byte offset 2 bit, word offset 2 bit, offset toplam 4 bit.
  - Tag $= 32 - 10 - 4 = 18$ bit.

- Blok boyutunu büyütmek miss oranını bir noktaya kadar düşürür.
  - Daha büyük bloklarda iyileşme durur. Sabit kapasitede satır sayısı azaldığı için miss oranı tekrar artmaya başlar.

Direct mapped cache: adım adım örnek

- Bellekte 0x10, 0x14, 0x18, 0x1C adreslerinde a, b, c, d; 0x30–0x3C adreslerinde e, f, g, h vardır.
- İşlemci sırayla 0x14, 0x1C, 0x34, 0x8014 adreslerinden okur. Başta bütün valid bitleri 0'dır.

Adres	Tag	Index	Word offset	Sonuç
0x14	0	1	1	Miss (valid = 0). a, b, c, d bloğu 1. satıra yüklenir, b okunur.
0x1C	0	1	3	Hit (valid = 1, tag eşit). d okunur.
0x34	0	3	1	Miss (valid = 0). e, f, g, h bloğu 3. satıra yüklenir, f okunur.
0x8014	2	1	1	Miss (valid = 1 ama tag 0 ≠ 2). 1. satırdaki blok yenisiyle değiştirilir.

- 0x1C'nin hit olması uzamsal yerelliğin etkisidir: 0x14 okunurken bütün blok gelmişti.
- 0x8014 bir çakışma (conflict) miss'idir. Direct mapped yapıda o bloğun gidebileceği tek satır 1. satırdır.

Ortalama erişim süresi

- $T_a = T_c + (1 - H)\, T_m$.
  - Miss durumunda önce cache'e bakılır, sonra ana belleğe gidilir. Bu yüzden miss süresi $T_c + T_m$ olarak alınır.
- Örnek: $H = 0.85$, $T_c = 5$ ns, $T_m = 50$ ns.
  - $T_a = 5 + 0.15 \cdot 50 = 12.5$ ns. Cache olmadan 50 ns olurdu.
- İki seviyeli örnek: L1 hit süresi 1 cycle, L1 miss oranı %5; L2 hit süresi 5 cycle, L2 miss oranı %15; ana bellek 100 cycle.
  - L1 miss cezası $= 5 + 0.15 \cdot 100 = 20$ cycle.
  - AMAT $= 1 + 0.05 \cdot 20 = 2$ cycle.

Yazma politikaları ve LRU

- Write-through:
  - Her yazmada veri hem cache'e hem ana belleğe yazılır. Bellek ve cache her zaman tutarlıdır.
  - Bedeli: her yazma ana bellek trafiği üretir.
- Write-back:
  - Yazma yalnız cache'e yapılır, satırın dirty biti 1 olur.

  - Satır başka bir blokla değiştirileceği zaman dirty biti 1 ise önce ana belleğe yazılır.
- Fully associative örnekte (2 satırlık cache) LRU biti her erişimde güncellenir.
  - Yeni blok, boş satıra ya da en uzun süredir kullanılmayan satıra yerleşir.
  - Örneğin devamı (write-back sürümü dahil) öğrencilere bırakıldı.

Bitiş örneği: üç eşleme tekniğinde alanlar

- Verilenler: adres 32 bit, veri yolu 64 bit (1 word = 8 byte), cache 2 MB (tag hariç), line = 32 byte = 4 word.
- Byte offset $= \log_2 8 = 3$ bit, word offset $= \log_2 4 = 2$ bit.

Teknik	Tag	Index	Word offset	Byte offset
Fully associative	27	—	2	3
Direct mapped	11	16	2	3
2-way set associative	12	15	2	3

- Direct mapped: satır sayısı $= 2^{21}/2^5 = 2^{16}$, index 16 bit.
- 2-way: her set yarı kapasiteyi alır. Satır sayısı 2^{15}, index 15 bit, tag 1 bit artar.

Ders sonrası notlar

- Hoca interface sorusunu anlatırken bir yerde “A1 ucu birinci interface’in chip select ucuna bağlanacak” dedi. Hemen ardından doğrusunu söyledi: A0 birinci, A1 ikinci interface’e bağlanır.
- Gordon Moore derste “Intel’de çalışan bir iktisatçı, işletmeci” diye anlatıldı.
  - Moore bir kimyagerdir ve Intel’in kurucularındandır.
  - Moore Yasası, bir yongadaki transistör sayısının yaklaşık her iki yılda bir ikiye katlanmasıdır.
  - “İşlemci yılda %60, DRAM yılda yaklaşık %7–9 hızlanıyor” karşılaştırması Moore Yasası değildir. Bu, Hennessy & Patterson’ın işlemci-bellek performans açığı (processor-memory gap) grafiğidir.
- Hoca LRU’yu anlatırken “direct map cache’te ne yapıyorduk? Aynı indekse sahip dört set var” dedi. Bu cümlede kastedilen set associative cache’tir. Direct mapped yapıda her index için tek satır vardır.
- Slayttaki bellek hiyerarşisi şekli eski bir mimariye aittir. Günümüz işlemcilerinde L2 (çoğunlukla L3 de) işlemci yongasının içindedir.
- Miss durumunda bloğun cache’e yazılmasının ayrıca süre eklemediği söylendi. Bu, dersteki basit modelin varsayımıdır. Gerçek sistemlerde blok yükleme (ve write-back’te dirty bloğun geri yazılması) miss cezasının bir parçasıdır.
- Tüm sayısal sonuçlar (12.5 ns, 20 ve 2 cycle, 0x8014 için tag 2 ve index 1, bitiş tablosu) Python ile doğrulandı.

Not: İsterseniz bu dersin altyazı (.srt) dosyasını Gemini Notebook gibi bir yapay zeka aracına yükleyerek ders hakkında daha detaylı soru-cevaplar yapabilir ve dersi daha verimli çalışabilirsiniz.