Ders 3 Çalışma Özeti

Ders 3 Çalışma Özeti

Tarih: 4 Haziran 2026 Perşembe. Online ders, dönemin son konu anlatımı. Süre yaklaşık 1 saat 5 dakika. Slaytlar büyük olasılıkla Prof. Dr. M. Fatih Amasyalı'nın ders notlarından ("YZ etik").

Genel Konular

- Etik (ahlak) ve hukuk kavramları, aralarındaki fark.
- Yapay zekanın karar veren sistem olarak özel durumu: ölçek, kara kutu, önyargı, kültürel bağımlılık.
- Verilerdeki önyargı (bias) ve türleri. Önyargıyı azaltma yöntemleri.
- Korelasyon ile nedensellik (causality) karışıklığı.
- Sorumluluk: Yapay zekanın yanlış kararında suçlu kim?
- Açıklanabilirlik (explainability), kara kutu sorunu ve GDPR.
- Yapay zeka ve işsizlik: karamsar ve iyimser senaryolar, meslek risk haritası.
- Manipülasyon: sosyal medya algoritmaları, tıklama optimizasyonu, deepfake.
- Kişisel verilerin gizliliği ve sürekli izlenme.
- Avrupa Birliği Yapay Zeka Yasası (EU AI Act) ve etik ilkeler.
- Genel yapay zeka (AGI) ve otonom silahlar.

Hocanın Özellikle Vurguladığı Kısımlar

- Hukuki olan her şey etik değildir. Yapay zekanın kararları hukuk ve etik açısından ayrı ayrı değerlendirilmelidir.
- Etik kurallar zamandan ve kültürden bağımsız değildir. Kölelik bir zamanlar hukukiydi.
- Bir insanın önyargısı tek bir şirketle sınırlı kalır. Aynı önyargı yapay zekaya öğretilirse milyonlarca karara yayılır.
- Model, verideki önyargıyı da öğrenir. Önyargılı veriyle eğitilen yapay zeka önyargılı karar verir.
- Birlikte değişen şeyler her zaman neden-sonuç ilişkisi içinde değildir. Korelasyonu nedensellik sanmak yapay zekayı yanıltır.
- Yalnız genel ortalama başarıya bakmak yeterli değildir. Her alt grupta hata oranı ayrı ayrı ölçülmelidir.
- İnsanların yapay zeka kararına itiraz etme ve açıklama talep etme hakkı vardır.
- Kullanıcı olarak sözleşme ve veri paylaşım metinlerini okuyun. Haklarınızı ve sorumluluklarınızı bilin.

Kısa Tekrar Notları

- Etik: iyi ve kötünün ne olduğuna dair, genellikle sözlü ve geleneksel ilkeler.
- Hukuk: devletlerin veya ülkeler arası anlaşmaların yazılı kuralları.
- Yapay zekanın özel durumu:
  - ölçek: milyarlarca karar,
  - kara kutu: kararın gerekçesi açıklanamıyor,
  - önyargı,
  - hız ve maliyet avantajı.
- Önyargı türleri:
  - tarihsel (historical): geçmişteki ayrımcılık veriye yansır,
  - temsil (representation): bazı gruplar az temsil edilir,

  - ölçüm (measurement): bazı gruplar için veri daha hatalı ölçülür,
  - toplama (aggregation): farklı gruplar tek modelle temsil edilir.
- Önyargıyı azaltma: dengeli (temsili) veri toplama, alt grup testleri, adillik metrikleri (eşit hata oranı, demografik parite, eşit fırsat).
- Açıklanabilir yapay zeka araçları: LIME, SHAP, Grad-CAM.
- Önyargı ölçme araçları: IBM AI Fairness 360, Google What-If Tool, Microsoft Fairlearn.
- AB'nin güvenilir yapay zeka için 7 ilkesi: insan gözetimi, teknik sağlamlık ve güvenlik, gizlilik ve veri yönetişimi, şeffaflık, çeşitlilik ve adalet, toplumsal ve çevresel refah, hesap verebilirlik.
- EU AI Act cezası: 35 milyon avroya veya yıllık cironun %7'sine kadar.

Detaylı Açıklamalar

Etik ve hukuk

- Varsayımsal örnek: Bir devlet "adı Ahmet olanlar tıp okuyamaz" diye bir yasa çıkarabilir. Bu hukuki olur ama etik olmaz.
- Tarihsel örnek: Endülüs'ün düşüşünden sonra İspanya'da Müslüman ve Yahudilerin Hristiyanlaştırılması ve Engizisyon mahkemeleri. Yargılamalar yazılı kurallara göre yapıldı, yani "hukuka uygundu", ama etik değildi.
- Kredi, işe alım, mahkeme kararı gibi konularda yapay zeka karar verebiliyor. Bu kararların hem hukuki hem etik olup olmadığı ayrıca sorgulanmalı.
- Kültürel bağımlılık: Bir yerde doğru kabul edilen şey başka bir yerde yanlış kabul edilebilir. Yapay zeka hangi kültürün etiğine göre karar verecek?

Verilerdeki önyargı

- Bilmece: Baba ve oğlu kaza geçirir. Cerrah "Bu benim oğlum, ameliyat edemem" der. Çoğumuz cerrahın erkek olduğunu varsayarız. Oysa cerrah çocuğun annesidir. Meslek tahmininde cinsiyet kullanan bir model bu önyargıyı öğrenebilir.
- Sıradan şeyler yazıya geçmez: İnternette "sarı muz" ifadesi, "yeşil muz" veya "kırmızı muz"a göre az geçer. "Öldürdü" ifadesi "yemek yedi"den çok daha sık geçer. Bu verilerle eğitilen model dünyayı çarpık görür. Köpek insanı ısırırsa haber olmaz, insan köpeği ısırırsa haber olur.
- Amazon (2018): CV değerlendirme algoritmasının kadın adaylara düşük puan verdiği ortaya çıktı. Sistem kaldırıldı.
- Yüz tanıma (bir MIT araştırmacısının çalışması, büyük olasılıkla Gender Shades): Ticari sistemlerde açık tenli erkeklerde hata yaklaşık %1, koyu tenli kadınlarda yaklaşık %35. Nedeni dengesiz (imbalanced) veri seti.
- Kredi döngüsü: Kredi alamayan mahalle sakinlerinin kredi geçmişi oluşmaz. Model onlara düşük puan verir. Döngü kendini pekiştirir.
- Toplama önyargısı örneği: Kanserin alt türleri tek bir "var" sınıfına indirgenirse model "var" sınıfını iyi tanıyamayabilir.
- İsim önyargısı: Aynı CV'lerde "Emily" gibi isimler, "Lakisha" gibi isimlere göre yaklaşık %50 daha fazla geri dönüş almış. Altyazıda yalnız "Emily" ve bozuk biçimde "Lakisha" geçiyor; "Greg" ve "Jamal" örnekleri büyük olasılıkla (slayttan).
- COMPAS: ABD'de sanıkların yeniden suç işleme riskini tahmin eden sistem. Siyahi sanıklar beyazlara göre yaklaşık iki kat daha sık yanlışlıkla "yüksek riskli" etiketlenmiş. Hakimler bu skoru ceza kararında kullanıyordu.

Korelasyon ve nedensellik

- Makine öğrenmesinde $y = f(x)$ fonksiyonu aranır. Bu, x'in değişiminin y'yi etkilediği varsayımıdır.
- Yazın dondurma ve terlik (veya klima) satışları birlikte artar. Aralarında nedensellik yoktur, ortak neden sıcaklıktır.
- Sahte korelasyon örnekleri:
  - 1990-2010 arasında internetin yaygınlaşması ve ağaçların azalması,
  - sosyal medyada kedi fotoğraflarının artması ve trafik kazalarının artması,

  - kadınlara oy hakkı verilmesi ve 1900'lerde dünya savaşlarının çıkması (hoca "trajikomik" dedi; arada mantıklı bir ilişki kurulamaz).
- Yoğun bakımda ölüm oranı yüksektir. Model "yoğun bakım ölüme yol açar" gibi ters bir neden-sonuç ilişkisi öğrenebilir.
- Belirli bir meslekteki insanlar ekonomik kriz yüzünden kredilerini ödeyemediyse, model o mesleği riskli sayabilir. Gerçek neden kriz olabilir.
- Doğru karar için nedensel çıkarım (causal inference) ve gerekirse alan uzmanı veya uzman sistem gerekir.

Sorumluluk

- Uber (2018): Otonom araç bir yayaya çarptı ve yaya öldü. Suçlu kim: yazılımcı, üretici, araçtaki sürücü, düzenleme yapmayan devlet, yaya?
- Radyoloji örneği: FDA onaylı bir model kanseri gözden kaçırır, teşhis gecikir. Sorumlu FDA mı, yazılım mı, son kararı veren doktor mu?
- Olası sorumluluk türleri: ürün sorumluluğu, ihmal, ortak sorumluluk.
- Bu alanda bilinen ilk kapsamlı düzenleme, risk seviyesine göre kademeli olan AB Yapay Zeka Yasası'dır.

Açıklanabilirlik

- Derin öğrenme modelleri çok sayıda parametreyle karar verir. Örneğin bir CNN'de filtre ve ağırlıkların neden o değerde olduğu açıklanamaz.
- Neden gerekli?
  - Hukuki hak: GDPR kapsamında kişi, hakkındaki otomatik karar için açıklama talep edebilir.
  - Güven: Doktorun yapay zekayla koyduğu teşhise ne kadar güvenebilirim?
  - Hata ayıklama: Önyargı ancak modelin nasıl karar verdiği görülünce tespit edilebilir.
  - İtiraz hakkı.
- Banka örneği: Kredi kartı limit artırma talepleri "değerlendirmemiz sonucunda reddedilmiştir" diye, gerekçesiz reddedilebiliyor. Otomatik sistem hatalı karar verebilir; gerekçe bilinmeyince itiraz da zorlaşır.
- Araçlar:
  - LIME: her tahmin için yerel doğrusal açıklama üretir.
  - SHAP: her özelliğin katkısını oyun teorisiyle (Shapley değerleri) hesaplar.
  - Grad-CAM: görüntü modelinin görüntüde nereye odaklandığını gösterir.
- AB Yapay Zeka Yasası (2024), yüksek riskli sistemler için açıklanabilirlik, insan denetimi ve kayıt tutmayı zorunlu kılıyor.

Yapay zeka ve işsizlik

- Karamsar senaryo: Rutin işlerin çoğunu yapay zeka ve robotlar devralır. Robotu tamir eden robot olunca insana neredeyse gerek kalmaz. Bazı ülkeler vatandaşlık maaşı (temel gelir) gibi düzenlemeler planlıyor.
- İyimser senaryo (tarihsel örüntü): Matbaa, dokuma makinesi, biçerdöver ve sanayi devrimi eski meslekleri yok etti ama yenilerini yarattı.
- Hocanın görüşü: Tarihsel örüntü bu kez tekrar etmeyebilir. Çünkü yeni yaratılacak görevlerin çoğunu da makineler devralabilir.
- Risk haritası:
  - Yüksek risk: veri girişi, belge sınıflandırma, rutin muhasebe, çağrı merkezi.
  - Orta risk: radyoloji okuma (yapay zeka okur, uzman kontrol eder).
  - Düşük risk: empatik bakım, liderlik, yaratıcı tasarım, karmaşık müzakere, sahne sanatları.
  - Yeni meslekler: prompt mühendisi, yapay zeka eğiticisi. Bunlar da ileride devralınabilir.
- Asıl soru: Dönüşümün yükünü kim taşıyacak, kim ne kaybedip ne kazanacak?

Manipülasyon

- Stuart Russell'a göre öneri algoritmaları, insanların ne istediğini öğrenmek yerine insanları daha tahmin edilebilir hâle getirerek hedefini optimize etti. İnsanlar bireysellikten uzaklaşıp yönlendirilebilir hâle geldi.
- Türler:
  - ticari: "X'i alma, Y'yi al",
  - siyasi: "A partisine değil, B'ye oy ver",
  - nefret politikaları.
- Tıklama oranı optimizasyonu: Hedef, kullanıcının platformda en uzun süre kalması. Hoca, Turkcell ile yaptığı doktora çalışmasında (2020) bir müzik uygulaması için akustik özelliklere dayalı müzik öneri sistemi geliştirdiğini anlattı.
- Cambridge Analytica: 87 milyon Facebook kullanıcısının verisi izinsiz alındı, psikografik profiller çıkarıldı. Bu profillerin ABD seçiminde kullanıldığı ileri sürüldü.
- Deepfake: Ses, görüntü, video ve metin gerçeğinden ayırt edilemeyecek kadar iyi üretilebiliyor. Hong Kong'da bir finans çalışanı, sahte bir video konferansta "CFO"nun talebiyle yaklaşık 25 milyon dolar transfer etti.

Kişisel veriler ve gizlilik

- Ham veri: tıklanan haberler, konum, alışveriş geçmişi, uyku saatleri, ziyaret edilen sayfalar.
- Target örneği: Alışveriş alışkanlıklarından hamile müşterileri tespit eden bir model kurdu. Bir baba, kızına gelen hamilelik ürünleri reklamlarından durumu öğrendi.
- Sigorta örneği: Bazı sigorta şirketleri Instagram paylaşımlarına göre prim belirlemek istiyor. Sigara içerken poz veren kişiye yüksek prim, koşarken fotoğrafı olana düşük prim gibi. Kullanıcılar da bu durumda yapay zekayı yanıltmaya çalışabilir.
- Olması gerekenler:
  - verinin hangi amaçla ve nasıl kullanılacağı açıkça söylenmeli,
  - kişi kendi verisini görebilmeli ve silebilmeli (ör. Google hesabı),
  - üçüncü taraflarla paylaşım için ayrıca onay alınmalı.
- Sağlık verileri erken teşhis için faydalıdır. Ama sigorta şirketleri, işverenler veya devletle sınırsız paylaşılmamalı. Gerekirse maskelenmiş veya anonimleştirilmiş paylaşılmalı.
- Çin'deki sosyal kredi sistemi: Trafik ihlali, kredi ödemesi gibi davranışlara göre puan verilir. Puanı düşenler uçuş ve tren yasağı gibi kısıtlamalarla karşılaşabilir. Hoca bunu Orwell'ın *1984*'ündeki "Büyük Birader"e (Big Brother) bağladı.

AB Yapay Zeka Yasası

- Yasaklanan sistemler:
  - sınırlı istisnalar dışında, halka açık alanlarda gerçek zamanlı uzaktan yüz tanıma,
  - sosyal skor sistemleri,
  - bilinçaltı manipülasyon teknikleri.
- Sıkı denetime tabi alanlar: sağlık, eğitim, istihdam, yargı, kritik altyapı. Bu alanlarda risk değerlendirmesi, şeffaflık ve insan denetimi zorunlu.
- Yaklaşım farkları: AB risk bazlı (önce temel hakları korumak için), ABD sektör bazlı, Çin devlet yönlendirmeli.
- Türkiye'de Kişisel Verileri Koruma Kanunu (KVKK) GDPR'a benzer korumalar sağlıyor. Yapay zekaya özel düzenleme çalışmaları sürüyor.

Geliştiriciler ne yapabilir?

- Yalnız k-katlı çapraz doğrulamanın ortalamasına bakmayın, alt grup testleri yapın.
- Eğitim verisinin nereden geldiğini belgeleyin.
- Model kartı (model card) yazın: amaçlar, kısıtlar ve başarısızlık senaryoları.

Genel yapay zeka ve geleceğe dair sorular

- Genel amaçlı bir yapay zekanın (AGI) değerlerini kim belirleyecek?
- Yapay zekanın hakları olacak mı?

- Otonom silahlar (“ölüm robotları”): Yaklaşık 30 ülke yasaklanmasını istiyor, uluslararası bir anlaşma henüz yok.
- Yapay zekanın hedefleri insanın etik ve ahlaki değerleriyle uyumlu olmalı. Umut veren gelişmeler: AB yasası, açıklanabilirlik araçları, artan yapay zeka okuryazarlığı.

Ders sonrası notlar

- Hoca, Gırnata’nın “galiba Aragon Krallığı”na düştüğünü söyledi. Gırnata (Granada) 1492’de Kastilya ve Aragon’un ortak hükümdarları Ferdinand ve Isabella’ya düştü. İspanyol Engizisyonu büyük olasılıkla 1478’de, Gırnata’nın düşüşünden önce kuruldu ve ilk hedefi Hristiyanlığa geçmiş Yahudilerdi.
- Hoca Hong Kong deepfake dolandırıcılığını 2023’e tarihledi. Olay büyük olasılıkla Ocak 2024’te yaşandı ve Şubat 2024’te duyuruldu. Transfer edilen tutar yaklaşık 200 milyon Hong Kong doları, yani yaklaşık 25 milyon ABD dolarıdır.
- Hoca Stuart Russell’ın tespitini 2020’ye tarihledi. Bu görüş büyük olasılıkla 2019’da yayımlanan *Human Compatible* kitabında yer alır.
- GDPR’da “açıklama hakkı” büyük olasılıkla açıkça yazılı tek bir madde değildir. 22. madde otomatik kararlara karşı insan müdahalesi ve itiraz hakkı tanır. 13-15. maddeler “işleme mantığı hakkında anlamlı bilgi” verilmesini ister.
- Yüz tanıma çalışması büyük olasılıkla Gender Shades’tir (Buolamwini ve Gebru, 2018). Orada en yüksek hata koyu tenli kadınlarda yaklaşık %34,7, en düşük hata açık tenli erkeklerde yaklaşık %0,8’dir; hocanın %1 ve %35 değerleri bunların yuvarlanmış hâlidir.
- İsim önyargısı çalışması büyük olasılıkla Bertrand ve Mullainathan’ın 2004 tarihli deneyidir. Karşılaştırılan isimler beyaz ve siyahi Amerikalılarla özdeşleşen isimlerdir.
- COMPAS’ın açılımı büyük olasılıkla Correctional Offender Management Profiling for Alternative Sanctions’tır. İki kat yanlış etiketleme bulgusu büyük olasılıkla ProPublica’nın 2016 analizine aittir.
- Altyazıda “IBM Payness” diye geçen araç büyük olasılıkla IBM AI Fairness 360’tır. LIME ve Grad-CAM’in yanında anlatılan oyun teorisine dayalı araç SHAP’tir.
- Çin’deki sosyal kredi sistemi büyük olasılıkla tek ve merkezi bir puan sistemi değildir; kurumlara ve şehirlere göre farklı uygulamalardan oluşur. “Yabancı marka telefon alınca puan düşer” iddiası büyük olasılıkla belgelenmiş bir kural değildir. Borcunu ödemeyenlere uçuş ve hızlı tren kısıtlaması ise belgelenmiş uygulamalar arasındadır.
- AB’nin 7 ilkesi büyük olasılıkla 2019’da yayımlanan “Güvenilir Yapay Zeka için Etik Yönergeler”den (Ethics Guidelines for Trustworthy AI) gelir. AB Yapay Zeka Yasası büyük olasılıkla 1 Ağustos 2024’te yürürlüğe girdi; hükümleri kademeli olarak uygulanıyor.
- 35 milyon avro ya da %7 üst sınırı büyük olasılıkla yasaklanmış uygulamaların ihlali içindir; yüzde, dünya çapındaki yıllık ciro üzerinden hesaplanır ve hangisi yüksekse o uygulanır. Diğer ihlallerde üst sınırlar büyük olasılıkla daha düşüktür.

Duyurular

- Bu dersle dönemin konuları tamamlandı.
- Gelecek hafta büyük olasılıkla ders yapılmayacak; telafi sınavı olacak.
- Final sınavı büyük olasılıkla vizeye benzer olacak: tüm konuları kapsayan, tek doğru cevaplı test.
- Etik slaytı daha sonra paylaşılacak. Önyargı araçları ve çevrim içi kurslar için slayttaki kaynaklar incelenebilir.

Not: İsterseniz bu dersin altyazı (.srt) dosyasını Gemini Notebook gibi bir yapay zeka aracına yükleyerek ders hakkında daha detaylı soru-cevaplar yapabilir ve dersi verimli çalışabilirsiniz.