Ders 5 Çalışma Özeti

Ders 5 Çalışma Özeti

Genel Konular

- Morfolojik analizin kısa tekrarı ve sentaktik analize (söz dizimsel analiz, syntactic analysis) geçiş.
- Kelime türleri, durak kelimeler (stop words) ve sözcük türü etiketleri (part of speech, POS).
- Penn Treebank ve Brown etiket kümeleri, Türk dilleri için etiket kümesi.
- Türkçe ile İngilizcenin söz dizimi farkları: serbest sıralı söz dizimi (free word order).
- Bağlamdan bağımsız dilbilgisi (context-free grammar, CFG) ve ağaç derlemi (treebank).
- Kural tabanlı ve olasılık tabanlı çözümleme, yukarıdan aşağı ve aşağıdan yukarı ayrıştırma (parsing).
- Bağlılık ayrıştırması (dependency parsing).
- Türkçede tümce türleri ve cümleyi öğelerine ayırma.
- Genişletilmiş geçiş ağları (Augmented Transition Network, ATN).
- Dil modellerine giriş: lemma ve kök farkı, kullanım alanları, Shannon oyunu, n-gram fikri.
- Harf dizilerinde sıfırıncı, birinci, ikinci ve üçüncü derece yaklaşımlar.
- Romance dillerinde hece örtüşmesi ve Zipf yasası.
- Cümle olasılığının hesaplanması ve n-gram modeli.

Hocanın Özellikle Vurguladığı Kısımlar

- Bu dersin konsepti hazır araçları kullanmaktır. Morfolojik analizciyi öğrenciler yazmayacak.
- Morfolojik analiz bir kelimeye birden fazla çözüm verebilir. Hangisinin doğru olduğu bağlamdan (context) anlaşılır. Bu belirsizlik (ambiguity) sentaktik analizde çözülür.
- Tümce ile cümle, sözcük ile kelime aynı anlamdadır.
- Sık geçen bir kelime önemli demek değildir. “of” ve “in” çok sık geçer ama ayırt edici değildir.
- Stop words çoğu uygulamada atılır. Yazar tanıma (authorship) çalışmasında ise ayırt edici olabilir.
- Türkçe serbest sıralıdır. Aynı cümlenin birçok dizilişi vardır. Bu yüzden Türkçenin sentaktik çözümlemesi İngilizceden zordur.
- Kökü almak olumsuzluk ekini siler. Duygu analizinde (sentiment analysis) bu ciddi hata doğurur.
- Bağlılık ayrıştırması cümlenin öğelerini ve kelimeler arası ilişkileri verir. Hocaya göre bu çok önemlidir.
- Olasılık tabanlı çözümlemede önce en olası ağaç ya da yol denenir. Böylece çözümleme hızlanır.
- Lemma ile kök aynı şey değildir. Sözlükte bulunan kelimenin daha fazla köküne inilmez.
- Pratikte n değeri genellikle 2 ya da 3 alınır. Akademik çalışmalarda en fazla 4-5 görülür.
- Final sınavı yok. Final saatinde proje demosu yapılacak ve rapor teslim edilecek.

Kısa Tekrar Notları

- Sentaktik analizin amaçları:
  - Anlamsal analize (semantic analysis) girdi sağlamak.
  - Kelimelerdeki belirsizlikleri çözmek.

  - Cümlenin o dile ait olup olmadığına karar vermek.
  - Cümleyi öğelerine ayırmak.
- Kelime türleri: isim (noun), belirleyici (determiner), sıfat (adjective), fiil (verb), zarf ya da belirteç (adverb), edat ya da ilgeç (preposition), bağlaç (conjunction).
- Stop words: tek başına anlam taşımayan, cümle içinde anlama katkı veren kelimeler. Türkçesi durak kelimeler ya da fonksiyonel kelimelerdir.
- POS: bir dokümanda anlamı olan en küçük birim kelimedir. Her kelimeye bir etiket atanır.
- Ağaç derlemi: bir dilin cümle yapılarını gösteren ağaçların toplandığı derlem.
- CFG: her cümleye karşılık gelen bir ağaç olmalıdır.
- Kural tabanlı çözümleme: ağaçlar sırayla denenir. Olasılık tabanlı çözümleme: en olası ağaçtan başlanır.
- ATN: durumlar (state) ve geçişlerle gösterilen ağaç derlemi. Ağaçtan farkı yalnızca gösterimdir.
- Dil modeli: bir dildeki kelime dizilerinin olasılık dağılımı. Buna istatistiksel dil modeli denir.
- Karakter n-gram: harfi önceki harflere göre tahmin eder. Kelime n-gram: kelimeyi önceki kelimelere göre tahmin eder.
- Zipf yasası: kelimelerin sıklığı, sıralarıyla ters orantılıdır.
- Bigram ile cümle olasılığı: $P(S) = P(w_1) \times P(w_2|w_1) \times \cdots \times P(w_n|w_{n-1})$.

Detaylı Açıklamalar

Ders başı duyuruları

- Ödevler drive'a konuyor. Hoca bu gün ödevlere bakamayacağını söyledi. Yetiştiremeyenlere Cuma'ya kadar süre verdi.
- Seminer için makale seçilecek. Makale, öğrencinin proje konusuna yardımcı olacak bir konuda olmalı.
- Hoca proje konularına bakıp uygun makaleleri ödevlerin konduğu drive'a koyacak.
- Hocanın koyduğu makaleler uymuyorsa öğrenci kendi bulduğu makaleyi hocaya önerebilir. Hoca çok ağır makale seçilmesini istemiyor.
- Hoca, makaleleri koymayı unutursa bir öğrenciden kendisine hatırlatma maili atmasını istedi.
- Konu seçmeyen öğrencilerin proje konusunu seçmesi istendi.

Morfolojik analizin tekrarı

- Biçim bilimsel analiz (morphological analysis) metni token'lara, yani kelimelere ayırır.
- Sonra kelimeyi kök ve eklerine ayırır ve eklerin türünü verir.
- Bu çıktı sentaktik analizin girdisidir. Sentaktik analiz için kelimelerin etiketlenmiş olması gerekir.
- Örnek belirsizlik: "gül" hem isim hem fiil olabilir. Doğru çözüm, cümle ağaç derlemindeki bir ağaca oturunca anlaşılır.

Söz dizimsel analiz

- Tanım: söz dizimini oluşturan morfolojik öğeleri, hiyerarşik kurallara uyumlarına göre çözümlemek.
- Hiyerarşik kurallar, dil ve gramer konusundaki Chomsky hiyerarşisinden gelir.
  - Başlangıç sembolü S vardır.
  - Türetme kuralları P dilin cümle yapılarıdır.
  - Çözümleme sonunda her şey uç değişkenlere (V_T) iner.
- Önceki derslerde kurallarda soyut A, B sembolleri kullanıldı. Gerçek dünyada bunların yerine nesne, tümleç, ön ad gibi dilbilgisi öğeleri ya da POS etiketleri gelir.
- Bilgisayar, morfolojik analizden geçmiş rastgele kelimeleri de "cümle" sanabilir. Bu yüzden ona dilin söz dizimi yapısı verilmelidir. Burada otomatlar ve ağaç yapıları kullanılabilir.

Kelime türleri ve stop words

- İngilizcede belirleyiciler vardır: “the”, “a”, “an”. Türkçede belirleyici yoktur. “Bir kitap” ifadesindeki “bir” belirleyici gibi düşünülebilir.
- Sınıflandırma, kümeleme ya da cümle vektörü çıkarmada her kelimeyi kullanmak maliyetlidir. Bazı kelimelerin ayırt ediciliği yoktur.
- İngilizce bir derlemde (corpus) sıklıklar çok yüksektir. Örneğin “of” yaklaşık 540 bin, “in” yaklaşık 331 bin kez geçer.
- Zamirler (“it”, “I”, “he”, “you”), bağlaçlar (“and”, “that”, “but”) ve yardımcı fiiller de çok sık geçer.
- Hocayı şaşırtan nokta: “can”, “may”, “will”, “should” gibi kip fiilleri (modal), “have”, “do”, “is” gibi yardımcı fiillerden daha sık listelenmiş.
- “have” listede soru işaretiyle verilmiş. Çünkü hem yardımcı fiil hem asıl fiil olabilir.
  - Çözüm önerisi: bir zamirden ya da özneden sonra geliyorsa yardımcı fiil kabul edilebilir.
  - Yalnızca terim frekansı (TF) sayılırsa ve bu kontrol yapılmazsa önemli bilgi kaçabilir.
- Metin madenciliğinde (text mining) bu kelimeler ön işlemede (preprocessing) atılır.

Diller arası söz dizimi farkı

- Slaytta “O kalemini tek silahı olarak görür” anlamında bir cümle Türkçe, Japonca, Korece, Fince, Çince ve İngilizce olarak verildi.
- Türkçe, Japonca ve Korecede fiil sondadır. Hoca bu dilleri Ural-Altay ailesi olarak anlattı. Hepsi sondan eklemelidir.
- Fince, Çince ve İngilizcede fiil ortadadır.
- Aynı ailedeki diller arasında:
  - Bir dilin sentaktik analiz kodu küçük değişikliklerle diğerine uyarlanabilir.
  - Makine çevirisi (derin öğrenme öncesinde) daha başarılıdır. İngilizceden Almancaya çeviri, İngilizceden Türkçeye çeviriden bu yüzden daha başarılıdır.
- Türkçede kural: özne, nesne, tümleç, yüklem. Yüklem başa gelirse buna devrik cümle denir.

POS etiket kümeleri

- Etiketler keyfi atanmaz. İngilizce için Penn Treebank ve Brown etiket kümeleri kullanılır.
- Türkçe çalışmalarda da bu kümeler kullanılır. Ancak İngilizcede olup Türkçede olmayan etiketler vardır (ve tersi). Bu yüzden eksiklikler oluşur.
- Morfolojik analizde hangi aracı kullanırsanız kullanın (örneğin Porter stemmer), etiketler bu kümelere benzer biçimde verilir.
- Hocaya göre etiketlerin hepsini ezberlemek gerekmez. Baktıkça göz alışır. Takılınca tabloya bakılır.

Etiket	Anlamı
CC	Sıralama bağlacı (coordinating conjunction)
JJ	Sıfat (adjective)
JJR	Sıfatın karşılaştırma hâli (comparative)
JJS	Sıfatın üstünlük hâli (superlative)
MD	Kip fiili (modal)
NN	Tekil isim
NNS	Çoğul isim
NNP	Tekil özel isim
NNPS	Çoğul özel isim
POS	İyelik eki (’s)
VB	Fiil, yalın hâl
VBD	Fiil, geçmiş zaman (past tense)
VBG	Fiil, -ing hâli
VBN	Fiil, üçüncü hâl (past participle)
VBZ	Fiil, üçüncü tekil şahıs, geniş zaman

- Zamirler için de etiket vardır. Hoca bunu “PP” olarak gösterdi. “Benimki, seninki” gibi sahiplik bildiren zamirlere ek bir işaret konur.
- Noktalama gibi özel işaretler için de etiketler vardır.
- CFG kurallarında artık A, B yerine bu etiketler yazılır. Örneğin bir cümle kuralı NN ve onu izleyen bir etiketten oluşabilir.
- Türk dilleri için ayrı bir etiket kümesi geliştirilmiştir. Slaytta Türkçe, Tatarca, Başkurtça, Kazakça gibi diller için sütunlar vardır.
  - Örneğin yönelme eki (dative) için etiket vardır. İngilizcede böyle ekler yoktur.
  - Sayılar, kişiler, zamanlar ve soru ekleri için de etiketler vardır.
  - Hocanın gözlemi: Türkçe çalışmalarda bile çoğunlukla İngilizce etiketler kullanılıyor. Eksik etiket olursa araştırmacı kendi etiketini ekliyor.

Türkçe ile İngilizcenin farkları

- İngilizcede tanımlık (“the”, “a”, “an”) vardır. Türkçede yoktur.
- İngilizcede ön edatlar (preposition: “of”, “in”, “by”) vardır. Türkçede bu iş eklerle ve son edatlarla yapılır.
- İngilizcede sıfat derecelendirmesi ekle yapılır (“-er”, “-est”). Türkçede ayrı kelime eklenir: “büyük top”, “çok büyük top”, “daha büyük top”, “kocaman top”. Zarflarda da durum aynıdır.
- İngilizcede “up”, “off” gibi fiil parçacıkları vardır. Türkçede yoktur.
- Türkçe fiiller kurallıdır ama içinde hem kişi hem zaman bilgisi taşır. Örneğin “okuyor” kelimesinde “o” kişisi ve zaman bilgisi vardır. Bu yüzden Türkçe fiili çözümlemek İngilizceden çok daha zordur.
- Türkçe eklemeli bir dildir. Yapım eki çok fazladır. Bir kökten çok farklı kelimeler türetilebilir.
- Türkçe serbest sıralı söz dizimine sahiptir. Kelimelerin yeri değişse de anlam bozulmaz:
  - “Ben kıza çiçek verdim.”
  - “Kıza çiçeği ben verdim.”
  - “Ben çiçeği kıza verdim.”
  - “Çiçeği kıza ben verdim.”
  - “Kıza ben verdim çiçeği.”
- Bu yüzden aynı cümle için birçok ağaç gerekir.
- İngilizcede sıra çok kısıtlıdır. “She saw him” cümlesi “the tall woman”, “the fat man with red beard” gibi genişletilebilir ama kelimelerin yeri değiştirilemez.
- Türkçede de yer değiştirmenin anlamı değiştirdiği durumlar vardır:
  - “Sınavı zor yetiştirdim”: “zor” fiili niteler, zarftır. Süre yetmemiştir.
  - “Zor sınavı yetiştirdim”: “zor” ismi niteler, sıfattır. Sorular zordur.

Sentaktik analizin problemleri

- Bir kelime birden fazla sınıfa girebilir. İngilizcede “this”:
  - “This is a nice day.”: zamir.
  - “This day is nice.”: belirleyici.
  - “You can go this far.”: zarf.
- Türkçede de durum aynıdır. Basit bir kural: kelime ismin önündeyse sıfat, fiilin önündeyse zarftır.
- Sözcük öbekleri farklı kalıplarda olabilir: ad (isim) tamlaması, ön ad (sıfat) tamlaması, eylem tümcesi, ad tümcesi.
- Slayttaki istatistiğe göre dünya dillerinde özne-nesne-yüklem dizilişi yaklaşık %46 oranındadır.
- Tümceler anlamlarına göre olumlu, olumsuz, bildirme, soru, emir, istek ve ünlem tümceleri olabilir.
- Olumsuzluk eki örneği:
  - “Öğretmen bana şunu yapmamamı söyledi.”
  - Köke indirgenince “yapmamamı” kelimesi “yap” olur. Olumsuzluk eki kaybolur.
  - Sözlük (lexicon) tabanlı duygu analizinde cümle bu yüzden yanlış sınıflanır.
  - Çözüm: morfolojik analizde olumsuzluk eki (“-ma”, “-me”) görülürse kelime yalnızca kök olarak alınmamalı.

Çözümleme yaklaşımları

- En klasik yöntem bağlamdan bağımsız dilbilgisidir (CFG). Kural tabanlıdır.
- Slaytta diğer dilbilgisi modelleri de geçti: sözcüksel işlevsel dilbilgisi (Lexical Functional Grammar), ulamsal dilbilgisi (Categorial Grammar), başsözcüğe dayalı öbek yapısal dilbilgisi (Head-driven Phrase Structure Grammar), bağlılık dilbilgisi (Dependency Grammar). Hoca CFG'yi referans alarak ilerledi.
- Chomsky hiyerarşisinin tekrarı:
  - Tür 0: kısıtsızdır. Kuralların iki tarafına istenen sayıda sembol yazılabilir. Turing makinesiyle gerçekleştirilenler buradadır.
  - Tür 1: sol taraftaki sembol sayısı sağ taraftakinden küçük ya da ona eşittir.
  - Tür 2: bağlamdan bağımsız dilbilgisidir.
  - Tür 3: düzenli dillerdir.
- CFG, bir cümle ile o cümlenin söz dizimini gösteren ağaç arasındaki ilişkiyi belirler. Her cümle, ağaç derlemindeki bir ağaca oturmalıdır.

Olasılık tabanlı çözümleme

- Bir cümle yapısını derlemdeki birden fazla ağaç çözebilir. Her ağacın bir olasılığı vardır.
- Örnek: özne-nesne-yüklem yapısındaki bir cümleyi T_1 ağacı %40, T_{15} ağacı %60 olasılıkla çözüyor.
- Önce en olası ağaç denenir. Cümle otururs hem çözümleme bitmiştir hem de cümle o dile aittir.
- Oturmazsa sonraki ağaca geçilir.
- Örnek: "Sınavı zor yetiştirdim" ve "Zor sınavı yetiştirdim". "zor" sıfatsa bir ağaç, zarfsa başka bir ağaç cümleyi çözer.
- Hiçbir ağaç çözemezse kelimelerde yazım hatası olabilir. İki seçenek vardır:
  - Ön işlemede hatalı kelimeleri düzeltmek. Bu da bir maliyettir.
  - Cümleyi "çözümlenemedi" diye ayırmak, sonra bakıp düzeltmek ve yeniden ağaca vermek.

Bağlılık ayrıştırması (dependency parsing)

- Sentaktik analizin en önemli parçalarından biridir.
- İngilizce için açık kaynak araçlar vardır. Python kütüphanelerinde bulunur.
- Türkçe için akademik çalışmalar vardır ama kullanılan Zemberek'te yoktur.
  - Bu araçlar genelde açık kaynak sunulmuyor. Akademik kullanım için imzalı izin formu dolduruluyor (ticari kullanmayacağım diye).
  - Teknik Üniversite'den Gülşen Hoca'nın doktora tezi Türkçe çözümleme üzerinedir. Bir pipeline oluşturup öğrencilere web üzerinden açmıştır. Ancak cümleyi gönderip sonucu beklemek zaman kaybı olduğu için pek tercih edilmez.
- Örnek cümle: "Bu okuldaki öğrencilerin en akıllısı şurada duran küçük kızdır."
  - Morfolojik analiz her kelimenin kökünü, ekini ve etiketini verir. Örneğin "okul-da-ki": bulunma hâli ("-da"), ardından "-ki" eki kelimeyi sıfat yapar.
  - Sentaktik analiz cümleyi derlemdeki bir ağaca oturtur. Bütün kelimeler yapraklara yerleşir.
  - Bağlılık ayrıştırması dile ait kurallarla kelimeleri birbirine bağlar:
    - "-ki" eki önündeki ismi niteler.
    - Sıfat önündeki ismi niteler: "küçük" kelimesi "kız" kelimesini niteler.
    - "duran" kelimesindeki "-an" eki "kız" kelimesini niteler.
    - "kızdır" kelimesi "kızmak" fiili de olabilir. Ancak önünde sıfat olduğu için isimdir. Bu yüzden yüklem "kızdır" olur.
  - Bu ilişkiler bilinirse 5N1K soruları cevaplanabilir: "Öğrencilerin en akıllısı kimdir?", "Nerede duruyor?", "Neredeki öğrencilerin en akıllısı?".
- Cümlenin öğeleri (özne, nesne, tümleç, yüklem, zarf tümleci) bağlılık ayrıştırmasından elde edilir.

Türkçede tümce türleri

- Gösterim: TT temel tümce, YT yan tümcedir. Bir cümle yalnızca temel tümceden ya da birkaç yan tümce ve bir temel tümceden oluşabilir.

Tür	Örnek	Açıklama
Basit tümce	Çocuk duvarı boyadı.	Özne “çocuk”, nesne “duvarı”, yüklem “boyadı”.
Ortak öğesiz birleşik tümce	Çocuk duvarı boyarken adam geldi.	Özneler farklı. “Çocuk duvarı boyarken” yan cümlesi “geldi” yükleminin zarf tümlecidir.
Ortak öğeli birleşik tümce	Çocuk duvarı boyarken elini boyadı.	“Çocuk” iki tümcenin de ortak öznesidir.
Ortak özneli bağımlı sıralı tümce	Çocuk duvarı boyadı ve gitti.	İki tümce “ve” ile bağlanır. Özne ortaktır. İkinci tümcede gizli öznedir.
Ortak nesneli bağımlı sıralı tümce	Parayı ben kazanıyorum, eşim harcıyor.	Özneler farklı, nesne “para” ortaktır.
Birden fazla ortak öğeli tümce	Çocuk evde oyun oynarken televizyon izliyor.	İki tümcenin öznesi de “çocuk”.
Sıralı (bağımsız) tümceler	Bahar geldi, çiçekler açtı.	Tümceler birbirinden bağımsızdır.
Girişik tümce	Atatürk “Çalışmayan insan yükselemez.” diyor.	Tırnak içindeki tümce nesnedir. Çözümlemesi en zor yapıdır.

- Hocaya göre girişik tümceler karmaşık görünse de sorun değildir. Ağaç derleminde bu yapıyı çözen bir ağaç varsa öğeler kolayca etiketlenir.
- Tümcede yüklem mutlaka vardır. Özne gizli olabilir. Örneğin “Geldim” kelimesi hem kişiyi hem zamanı taşır. Öznesi gizlidir.
- Öğeleri bulmak için hangi soruların sorulacağı ve hangi sırayla bakılacağı slaytta verildi. Kaynak, Eşref Hoca’nın kitabıdır.
  - Önce ad öbekleri aranır: tek isim mi, ön ad (örneğin “büyük kırmızı ev”) var mı?
  - Çoğul eki, iyelik eki, yalın hâl kontrol edilir.
  - Sonra yüklem bulunur: çekimli eylem mi, ek eylem mi, birleşik eylem mi?

Öğelere ayırmanın blok diyagramı

```
Metin
  -> cümlelere ve kelimelere ayırma
  -> biçim bilimsel çözümleme
  -> belirsizlik giderme ve ön işleme
  -> ad tamlamaları, ön ad tamlamaları, ilgeç öbekleri, belirteç öbekleri
  -> yüklemin belirlenmesi
  -> öğelerine ayrılmış (etiketlenmiş) metin
```

- Ön işleme örneği: “ıspanak” kelimesi Türkçe karakter kullanılmadan “ispanak” yazılmışsa morfolojik analiz çözemez. Önce Türkçe karakter düzeltmesi yapılır.
- Belirsizlik giderme: biçim bilimsel çözümleme birden fazla sonuç verdiyse hangisinin alınacağına karar verilir.

Ağaç derlemi ve sözlükler

- Kurallardan ağaçlar oluşturulur. Örnek kurallar:

```
S  -> NP VP
S  -> Aux NP VP
S  -> VP
NP -> Det Nominal
```

```
NP -> ProperNoun
VP -> Verb NP
VP -> Verb
Nominal -> Noun
```

- Ağaçların yapraklarına sözlüklerdeki (lexicon) kelimeler gelir: isim sözlüğü, fiil sözlüğü (İngilizcede düzenli ve düzensiz fiiller ayrı), belirleyici sözlüğü, yardımcı fiil sözlüğü, özel isim sözlüğü.

Yukarıdan aşağı ayrıştırma örneği

- Cümle: "Does this flight include a meal?"
- `S -> NP VP` ağacında `NP -> Det Nominal` açılır. "does" belirleyici sözlüğünde yok. Bu ağaç olmaz.
- `NP -> ProperNoun` denenir. "does" özel isimler sözlüğünde de yok.
- `S -> Aux NP VP` ağacına geçilir. "does" yardımcı fiil sözlüğünde var. Yerleşir.
- "this" belirleyici, "flight" isim, "include" fiil, "a" belirleyici, "meal" isimdir. Hepsi yerleşir.
- Cümle bu ağaca oturduğu için çözümlenmiştir. Ardından bağlılık ayrıştırmasıyla anlamsal bilgi çıkarılabilir.

Aşağıdan yukarı ayrıştırma örneği

- Cümle: "Book that flight."
- "book" hem isim hem fiil sözlüğünde var. Bu bir belirsizliktir.
- Önce "book" isim alınır:
  - "that" belirleyici, "flight" isimdir. `Det Nominal` birleşip NP olur.
  - Geriye "book" (Nominal) ve NP kalır. Bunları birleştirip S yapan bir kural yok.
- "book" fiil alınır:
  - `Verb NP` birleşip VP olur.
  - `S -> VP` kuralı vardır. S'ye ulaşılır. Cümle İngilizcedir.
- Yani belirsizlik ağaçta ilerlerken çözülmüş olur.

Genişletilmiş geçiş ağları (ATN)

- Ağaç derlemi illa ağaç olarak gösterilmez. Genişletilmiş geçiş ağları da kullanılır (Augmented Transition Network, ATN ya da ATNG).
- Görsel olarak blok şemaya benzer. Dallanan ağaçlara göre daha derli topludur.
- Durumlar öznenin, yüklemin vb. kontrol edildiği yerlerdir. Bir durumdan sonrakine geçmek için soldaki durumun koşulu sağlanmalıdır.
- Slayttaki örnek ağ:

```
q1 --abb--> q2 --ε--> q3 --a--> q4 (final)
q3 --aa--> q1
q1 --b---> q4 (final)
```

- Tanınabilen metinler: "abba", "abbaaabba", "abbaab", "b". Tanınamayanlar: "abbab", "baab".
- "abbaaabba" çözümü:
  - "abb" ile $q_1 \rightarrow q_2$, ε ile q_3.
  - Burada "a" ile q_4 final durumuna gidilirse girdi bitmemiş olur. Bu yol yanlış.
  - "aa" ile q_1 durumuna dönülür. Yeniden "abb" ile q_2, ε ile q_3, "a" ile q_4.
  - Hem final durumuna gelinir hem girdi biter. Metin tanınır.
- "baab": "b" ile $q_1 \rightarrow q_4$ gidilir. q_4 durumundan çıkış yoktur ve girdi bitmemiştir. Metin tanınmaz.

ATN ile Türkçe cümle örneği: "Ali camı kırdı"

- Token'lara ayrılır ve morfolojik analize gönderilir: "Ali" isim, "cam" isim + "-ı" nesne eki, "kır" fiil + "-dı" zaman eki.
- "kır" kelimesi "çimlik alan" anlamında isim de olabilir. Ağaçta ilerlerken doğrusu anlaşılır.
- Adımlar:

  - İlk okunan öğenin özne olması beklenir. “Ali” isim sözlüğünde var. Özne alt ağı final durumuna gelir. Özne tamam.
  - “camı” kelimesi için iki yol vardır: yüklem ya da nesne.
  - Yüklem yolu: “cam” fiil sözlüğünde yok. Bu yol başarısız olur.
  - Nesne yolu: “cam” isim sözlüğünde, “-ı” nesne ekleri sözlüğünde var. Nesne tamam.
  - “kırdı”: “kır” fiil sözlüğünde, “-dı” zaman ekleri sözlüğünde var. Yüklem tamam.
  - Final durumuna gelinir ve girdi biter. Cümle çözümlenmiştir.
- Olasılık kullanımı: Türkçede özneden sonra nesne gelme olasılığı örneğin %80, yüklem gelme olasılığı %15 ise önce nesne yolu denenir. Bu oranlar hocanın verdiği varsayımsal örnektir.
- ATN döngüye (loop) izin verir. Bir ismin önüne kaç sıfat geleceği bilinmez: “yırtık kırmızı büyük top”. Her sıfatta aynı duruma dönülür. İsim gelince durulur.

Tam örnek: cümlenin hiyerarşik yapısı

- Cümle: “Ahmet’in babası beyaz şirin koyunu araba ile köye getirdi.”
- Ön işleme: yanlış yazılmış kelimeler düzeltilir (“sirin”, “koy” gibi). Noktalama atılır. Türkçe karakter sorunları giderilir.
- Morfolojik analiz kökleri, ekleri ve etiketleri verir.
- Slayttaki etiketler: <İ> isim, <TE> tamlayan eki, <TNE> tamlanan eki, <S> sıfat, <NE> nesne eki, <DE> yönelme (dolaylı tümleç) eki, <F> fiil, <ZE> zaman eki. “ile” kelimesinin etiketi <DZ> olarak verilmiş. Hoca bu kısaltmanın açılımını hatırlamadı.
- Kurallar ve ağaç:

```
Ahmet<İ> in<TE>         -> <T>
baba<İ> sı<TNE>         -> <TN>
<T> <TN>                -> <İG>  -> Özne:          Ahmet'in babası
beyaz<S> şirin<S>       -> <S>
<S> koyun<İ>            -> <SG>
<SG> u<NE>              -> <SN>  -> Nesne:         beyaz şirin koyunu
araba<İ> ile<DZ>        -> <ZT>  -> Zarf tümleci:  araba ile
köy<İG> e<DE>           -> <DT>  -> Dolaylı tümleç: köye
getir<F> di<ZE>         -> <Y>   -> Yüklem:        getirdi
```

- Cümle ağaca oturduğu için öğelerine ayrılmıştır. Bu çıktı anlamsal analize girdi olur.

Soru cevaplama örneği

- Cümle: “Türkiye’nin başkenti Ankara’dır.” Soru: “Türkiye’nin başkenti neresidir?”
- Birinci yol: bağlılık ayrıştırması üzerinden gitmek. Daha zahmetli ve zaman alıcıdır.
- İkinci yol: örüntü (pattern) tabanlı, daha kurallı yöntem.
  - “Nere” sorusu bir yer (location), yani özel isim arar.
  - Aranan özel isim “başkent” kelimesinin yakınında olmalıdır.
  - “Türkiye’nin başkenti Ankara’dır”, “Ankara Türkiye’nin başkentidir”, “Başkent olan Ankara” gibi cümleler toplanır. Ankara ile başkentin birlikte geçtiği örüntüler çıkarılır.
  - Soru gelince bu örüntülere uyan dokümanlardan cevap çekilir.

Dil modelleri

- Bilgisayar okuduğunu insan gibi anlayamaz. İnsan kelimenin hangi nesneye karşılık geldiğini bilir. Çok anlamlı kelimenin anlamını bağlamdan çıkarır. Deneyimleriyle kafasında bir model kurar.
- Bilgisayara bu modeller verilmelidir. Bunlardan biri dil modelidir.
- Tanım: bir dildeki kelimelerin sıralanışının olasılık dağılımı, o dilin istatistiksel dil modelidir.
- Karakterlerin ve kelimelerin kullanım sıklıkları ile iki, üç, …, n kelimenin art arda gelme sıklıkları dil modelini oluşturur.

Lemma (başsözcük) ve kök farkı

- Lemma, Türkçede başsözcük olarak çevrilir. Sözlükteki madde başı kelimedir. Bundan türetilenlere sözcükbirim denir.
- Örnek: “göz”, “gözlük”, “gözlükçü”. Üçünün de kökü “göz” kelimesidir.
- Köke inilirse anlam kaybolur. “Gözlük” kelimesi gözle ilgili bambaşka bir şeydir. Göz sayılmak istenirse yine hata yapılır.
- Kural: kelime aldığı ekle sözlükte varsa daha fazla köküne inilmez. Buna lemmatization denir.
- İngilizcede durum kolaydır: “read”, “reads”, “reading” için kök “read” kelimesidir. “-s” ve “-ing” anlamı değiştirmez.
- Türkçede isim soylu bir kelimeye 24 farklı çekim eki, fiil soylu bir kelimeye 46 çekim eki gelebilir. Çekim ekleri anlamı değiştirmez.
- Bütün çekimli hâlleri sözlükte tutmak mantıklı değildir. Bu yüzden ekler ayrılır.
- Türkçede lemma olarak kullanılabilecek yaklaşık 70 bin kelime vardır.

Dil modellerinin kullanım alanları

- Konuşma tanıma (speech to text): şiveli “celiyorum” yazıya “celiyorum” olarak geçer. Morfolojik analiz bunu çözemez. Dil modeli bunun “geliyorum” olduğunu bulur.
- El yazısı tanıma (handwriting recognition): kâğıda kalemle yazılmış yazıdaki belirsiz harfler (S mi Z mi) dil modeliyle tahmin edilir.
- Yazım düzeltme (spelling correction): klavyede yanlış tuşa basılarak yazılan kelimeler düzeltilir.
- Makine çevirisi (machine translation).
- Optik karakter tanıma (OCR): taranan metin resim olur, OCR onu metne çevirir. “m” harfinin “in”, “u” harfinin “ii” okunması, “t” ile “l” harflerinin karışması gibi hatalar görülür. Hocaya göre günümüz OCR araçları çok başarılıdır.
- Woody Allen örneği (slayt):
  - Veznedara “I have a gub” yazan bir not verilir.
  - “gub” İngilizcede anlamlı bir kelime değildir.
  - Aday kelimeler “gun”, “gum”, “Gus” ve “gull” olabilir.
  - “gun” kelimesinin banka ile ilişki olasılığı daha yüksektir. Bu yüzden “gub”, “gun” olarak alınır.
  - Veznedar bunu beden dilinden anlar. Bilgisayar ise dil modeliyle anlar.

Shannon oyunu

- Bir harf verilir ve sonraki harf tahmin edilir. İlk harf “W” ise İngilizcede kalan 25 harften hangisi gelir?
- Kimse “J” ya da “K” demez. Akla en olası harfler gelir.
- Cümle başında “W” varsa genelde soru kelimesi gelir: “what”, “when”, “who”, “which”, “why”.
- “Wh” verilince aday harfler “a”, “e”, “o”, “y” olur. 26 harf 4 harfe iner.
- “What” geldikten sonra boşluk gelir. Ardından genelde bir yardımcı fiil gelir.
- Karakter n-gram modeli (character n-gram): harf, kendinden önceki harflere göre tahmin edilir.
- Kelime n-gram modeli (word n-gram): kelime, kendinden önceki kelimelere göre tahmin edilir. Örneğin “what” kelimesinden sonra “do” gelebilir.

Harf dizilerinde yaklaşım dereceleri

Derece	Yöntem	Sonuç
Sıfırıncı derece (zero-order approximation)	Torbadan harfler eşit olasılıkla, birbirinden bağımsız çekilir.	Tamamen anlamsız dizi.

Derece	Yöntem	Sonuç
Birinci derece (first-order)	Harfler bağımsız ama torbada dildeki sıklıklarına göre bulunur (Scrabble ya da Kelimelik oyunundaki gibi).	Sesli-sessiz dağılımı iyileşir ama hâlâ anlamsız.
İkinci derece (second-order)	Her harf, bir önceki harfe göre en olası harf seçilir.	“and”, “to be”, “best”, “dream” gibi kelimeler görünür.
Üçüncü derece (third-order)	Her harf, önceki iki harfe göre seçilir. Örneğin “wh” sonrası en olası “e”, “he” sonrası “y”.	“when”, “last”, “no”, “demonstration”, “recognition” gibi kelimeler oluşur.

- Derece arttıkça çıkan kelimeler dile ait olur. Cümlenin anlamı değil, dilin yapısı yakalanır.
- n değeri teorik olarak sonsuz olabilir ama mantıklı değildir. Pratikte en fazla 20’ye kadar kullanılabileceği gösterilmiştir. 20 kullanan çalışma yoktur.
- Sebep: bir kelimenin geçmişindeki 20 kelimeyle birlikte geçme olasılığı sıfıra çok yakındır. Naive Bayes gibi olasılık çarpan yöntemlerde sonuç neredeyse sıfır olur.

Romance dillerinde hece örtüşmesi

- Hint-Avrupa dillerinde trigram sıklıklarına bakılmış. İlk sıralarda “ion” gibi ortak trigram’lar çıkmış. Hocaya göre “ion” Türkçede ilk 100 trigram’a bile girmez.
- Sonra Romance dillerinde heceler incelenmiş. Her dilin en sık ilk k hecesinin diğer dillerde de bulunma yüzdesi:

Dil	100	200	300	400	500	561	Hece türü (type)	Hece sayısı (token)
Latince	%72	%86	%92	%95	%98	%100	561	3922
Rumence	%63	%74	%80	%84	%87	%90	1243	6591
İtalyanca	%75	%85	%91	%94	%96	%97	803	7937
Portekizce	%69	%84	%91	%95	%97	%98	693	6152
İspanyolca	%73	%87	%93	%96	%98	%99	672	7477
Katalanca	%62	%77	%84	%88	%92	%93	967	5624
Fransızca	%48	%61	%67	%72	%76	%78	1738	5691

- Latince hepsiyle örtüşür, çünkü hepsi Latinceden türemiştir.
- İtalyanca, Portekizce ve İspanyolca çok benzer. Bu dillerden birini bilen diğerini kolay anlar ve öğrenir.
- Fransızca diğerlerinden daha farklıdır.

Zipf yasası

- George Zipf ortaya atmıştır.
- Bir dildeki kelimelerin kullanım sırası ile sıklığı arasında ilişki vardır.
- Bu yalnızca dillerde değil, doğada da geçerlidir: göllerin derinlikleri, dağların yükseklikleri sıralanınca aynı eğri çıkar.
- Örnek: en sık kelime 100 kez geçiyorsa:
  - 2. sıradaki kelime yaklaşık $100/2 = 50$ kez,
  - 3. sıradaki yaklaşık $100/3$ kez,
  - 10. sıradaki yaklaşık $100/10 = 10$ kez geçer.
- Değerler tam değil, yaklaşıktır (50 yerine 47-52 gibi).
- Slayttaki formüller:
  - $n(r) \propto \frac{1}{r^\alpha}$: r. sıradaki kelimenin sıklığı. α sabit bir değerdir.
  - $f(n) \propto \frac{1}{n^\gamma}$.
  - α deneme ile bulunur. Her dil için α değerleri zaten çıkarılmıştır.

- Eğrinin bölgeleri:
  - Baştaki bölge: işlevsel sözcükler (stop words): “ve”, “veya”, “that”, “which”, “and”, “or”, “the”. Çok sık geçerler.
  - Orta bölge: ana sözcükler.
  - Kuyruk: seyrek kullanılan sözcükler.
- Türkçenin Sıklık Sözlüğü grafiği de aynı eğriyi verir. Diller arasında eğrinin şekli biraz değişir ama hepsi Zipf yasasına uyar.
- Bir dilin derleminde yalnızca karakter sıklıkları sıralansa bile aynı dağılım görülür.

Cümle olasılığı ve n-gram modeli

- Sıfır-gram (zero-gram) yaklaşımı:
  - Hiçbir kelime bir öncekine bağlı değildir.
  - Sözlük boyutu V (Türkçe için yaklaşık 70 bin) ise her kelimenin olasılığı $1/V$ olur.
  - Cümlenin olasılığı bu değerlerin çarpımıdır. Kelime sayısı arttıkça olasılık hızla küçülür.
  - Aynı cümlenin tekrar gelmesi ancak kopyala-yapıştırla olur. Bu yüzden bu yaklaşımla iş yapılmaz.
- Slayttaki “kesin” yaklaşım: her kelimenin olasılığı frekansına bağlıdır ve diğer kelimelerden bağımsızdır:

$$P(S) = P(w_1) \times P(w_2) \times \cdots \times P(w_n)$$

- Slayttaki “en kesin” yaklaşım (n-gram): her kelimenin olasılığı önceki kelimelere bağlıdır.
- Tam geçmişle yazılırsa:

$$P(w_1 w_2 w_3 w_4) = P(w_1) \times P(w_2|w_1) \times P(w_3|w_1 w_2) \times P(w_4|w_1 w_2 w_3)$$

- $P(w_2|w_1)$: w_2 kelimesinin w_1 kelimesinden sonra gelme olasılığı. w_2 başka kelimelerden sonra geliyorsa onların olasılıkları farklıdır.
- Sorun: bazı edebi metinlerde bir cümle bir paragraf kadar uzundur. 50 kelimelik bir cümlede son kelime için 49 kelimelik geçmiş gerekir. Bu mantıklı değildir.
- Bu yüzden n belirlenir. $n = 2$ (bigram) için:

$$P(w_1 w_2 w_3 w_4) \approx P(w_1) \times P(w_2|w_1) \times P(w_3|w_2) \times P(w_4|w_3)$$

- Yani tüm geçmişe değil, yalnızca $n - 1$ önceki kelimeye bakılır.

Sonraki ders ve sınav duyuruları

- Gelecek hafta: Markov modelleri ve örnekler, düzeltme (smoothing) ve belirsizlik giderme algoritması.
- Final sınavı yapılmayacak. Final saatinde öğrenciler projelerinin demosunu gösterecek ve raporlarını drive’a koyacak. Süre yetmezse aynı gün akşam saatlerinde devam edilecek.
- Vize yapılacak. Tarih, üniversitenin sınav modülünü ne zaman açtığına bağlı. Genelde 8. hafta civarı. Hoca değiştirme yetkisi olursa tarihin öğrencilerle birlikte belirleneceğini söyledi.

Ders sonrası notlar

- Hoca “okuyor” kelimesi için “geniş zaman” dedi. “Okuyor” şimdiki zamandır. Geniş zaman hâli “okur” olur.
- “Çocuk evde oyun oynarken televizyon izliyor” örneğinde hoca “ortak nesnem çocuk” dedi. Doğrusu “çocuk” kelimesinin iki tümcenin ortak öznesi olmasıdır.
- Hoca Fince, Çince ve İngilizceyi birlikte gösterip “Hint-Avrupa dilleri galiba” dedi. Bu üçünden yalnızca İngilizce Hint-Avrupa dilidir. Fince Ural (Fin-Ugor) ailesinden, Çince Çin-Tibet ailesindendir. Japonca ve Korecenin Altay ailesine bağlanması da dilbilimde tartışmalıdır.
- Slaytta $\gamma = 1 + \frac{1}{n^\alpha}$ yazıyor. Zipf yasasının literatürdeki bilinen biçiminde bu ilişki $\gamma = 1 + \frac{1}{\alpha}$ şeklindedir. Slayttaki ifade büyük olasılıkla yazım hatasıdır.

- Altyazıda Woody Allen örneği “I have gap” olarak geçiyor. Slayttaki doğru örnek “I have a gub” ifadesidir.
- Altyazıda “Romanca” geçen dil, slayttaki tabloda “Romanian” yani Rumencedir.

Not: İsterseniz bu kayıtları Gemini Notebook gibi bir araca atıp daha istifadeli hale getirebilirsiniz.