Ders 4 Çalışma Özeti

Ders 4 Çalışma Özeti

Genel Konular

- Birinci ödevin proje sunumları: hayat bilgisi veri tabanı üzerinde uygulamalar
  - Derste daha önce toplanan Türkçe hayat bilgisi veri tabanı (yaklaşık 500 isim ve 500 fiil için "kim kullanır, nerede bulunur, ne işe yarar, kimle neyle yapılır" gibi sorulara verilmiş cevaplar, Prolog `.pl` dosyaları) üzerinde öğrenciler farklı uygulamalar geliştirip sundu. Sunanlar burada adsız anılır.
  - Graf veri tabanıyla kelimeler arası yol bulma: Kelimeler ve cevaplar Neo4j graf veri tabanına düğüm, ilişki türleri de kenar olarak yüklendi; sorgu dili Cypher'dır. Kullanıcı iki kelime, sorgu sayısı ve ilişki sayısı (yol uzunluğu) verir; sistem iki kelime arasındaki ilişki yollarını bulur (ekrandan, 00:20:00). Örnek: "odun" ile "araba" arasında kesmek, kamp yapmak, ateş, ısınmak üzerinden giden bir yol. Yüklenen graf yaklaşık 38.777 düğüm ve 125 bin ilişki içeriyordu. Veri tabanındaki anlamsız cevaplar (ör. "şofben kim kullanır: sarı") anlamsız yollara yol açtı. Önerilen geliştirme: iki cümleden çıkarım yapıp kişi profili çıkarmak (ör. "Ali eve gitti" ve "Ali Akbil kullandı" cümlelerinden Ali'nin otobüse bindiği çıkarımı).
  - Regex ve word2vec tabanlı bilgi çıkarımı: Cümlelerden "nasıl, ne yaptı, nerede, ne zaman, neden, ne olur, kim" sorularının tek kelimelik cevapları çıkarıldı. Önce veri tabanından üretilen sözlük tablolarına (sıfatlar, fiiller, ham madde, yer, kim, ne olur, ne zaman, neden) bakılır; bulunmazsa regex şablonu çalıştırılır (ör. "nerede" için bulunma/ayrılma eki, "ne zaman" için "-dığında, -yorken", "neden" için "-dığı için, -dan dolayı, -dan ötürü"); o da bulamazsa veri tabanındaki kelimelerle word2vec benzerliğine bakılır (ekrandan, 00:40:00). Hoca, sistemin aslında cümlenin öğelerini bulduğunu ve ilgili tüm adayları listelediğini yorumladı.
  - Cümle zenginleştirme (data augmentation): Zemberek ile cümle öğelerine ve kök-eke ayrılır, isim ve fiillerin hayat bilgisindeki ilişkili kelimeleri cümleye eklenir. Örnek çıktı: "ali { bira ile } kahve içti", "ali { masa de/da } kahve içti", "ali { toz şeklinde } kahve içti" (ekrandan, 00:50:00). İlişkili kelime rastgele ya da en sık girilen cevaba göre seçilir. Kullanıcı üretilen cümleyi mantıklı/mantıksız diye işaretler; ilgili ilişkinin sayacı artırılır ya da azaltılır.
  - Görsellerle ilişki doğrulama: Her soru-cevap çifti için arama motorundan görsel getirilir, kullanıcıya cevabın görselle ilişkili olup olmadığı sorulur. "Evet" ilişkiyi doğrular, "hayır" ile kullanıcı yeni cevap ekler, "fikrim yok" kayıt yapmaz. Gözlenen sorunlar: Türkçe karakter dönüşümü yüzünden "taş"ın "tas" olması, bazı cevapların sözlükten kopyalanmış olması.
  - İlişki güven seviyesi: Rastgele bir ilişki gösterilir, kullanıcı evet derse sayaç +1, hayır derse -1 olur; sayaçlar birçok kullanıcıdan toplanıp raporlanır. Hoca, eşit sayıda evet ve hayırın sıfır vereceğini, yani oy sayısının bu yöntemde kaybolduğunu belirtti.
  - Doğruluk ve kapsayıcılık değerlendirmesi: İsimlerden ve fiillerden rastgele 100'er ilişki elle kontrol edildi; isimlerde %87, fiillerde %96 doğru bulundu. Kapsayıcılık için kelimeler Google Translate ile İngilizceye çevrilip WordNet'te arandı (WordNet'te 82.115 isim, 13.767 fiil; 486 isim ve 468 fiil eşleşti) ve WordNet'ten eş/zıt anlamlılar çekildi (zıt anlamlıların çoğu boş geldi) (ekrandan, 01:20:00). Zemberek sözlüğünde (28.884 kelime) 492 isim ve 420 fiil eşleşti. Üç kişiye "çanta" için bir dakikada akıllarına gelen ilişkileri yazdırıldı; ortalama yaklaşık %72'si veri tabanında vardı. Hoca tek kavramla yapılan bu ölçümün az olduğunu belirtti.
  - Kelimelerin iki boyutta görselleştirilmesi: İsim/fiil düğümleri ve altlarındaki cevap

kelimelerinden bir ağaç kuruldu; çocuğu olmayan düğümler silindi, aynı adlı düğümler birleştirildi (ekrandan, 01:31:40). En sık 100 kelime seçildi; her kelime için 100 boyutlu bir vektör, o kelimenin ağaçta bu sık kelimelere komşuluğuna (ebeveyne 2, iki üste 1 gibi puanlarla) göre doldurulduu. Elde edilen 1325×100 matris PCA ile 2 boyuta indirildi (ekrandan, 01:30:00). Yiyecekler, yapı malzemeleri gibi gruplar yan yana düştü.
  - FastText ile kelime temsili: Prolog dosyaları temizlenip "kömür rengi siyah" gibi dizilerden bir derlem kuruldu, FastText skip-gram modeli eğitildi. En yakın kelimeler ve analojiler denendi (ör. kömür:siyah :: deniz:?). Hoca, "altın" için "alt, altı" gibi kelimelerin gelmesinin FastText'in karakter n-gram (alt dizgi) kullanmasından kaynaklandığını, bunun FastText içinde kapatılabileceğini söyledi; ayrıca word2vec'in "kömür-siyah, deniz-mavi" tipi analojileri pek iyi yapamadığını belirtti. Daha çok kelimeyle sistematik deneme yapılmasını önerdi.
- Geçen dersin tekrarı: istatistiksel dil modelleri
  - Dil modeli iki temel şey yapar: bir dizinin ardından gelecek kelimeyi tahmin etmek ve bir cümlenin olasılığını bulmak.
  - Cümle olasılığının kullanım alanları: makine çevirisinde olası çeviriler arasından seçim, yazım düzeltme, sesten metne çeviri.
  - Sonraki kelimeyi tahmin etmenin kullanım alanı: metin üretme. Tahmin edilen kelime diziye eklenip devam edilir.
  - K (Markov derecesi) kaç önceki kelimeye bakıldığını gösterir. Metin üretirken sonraki kelimeler henüz yoktur, bu yüzden yalnız öncekiler kullanılır.
  - Unigramla üretilen metinde ardışık ikililer anlamlı, ardışık üçlüler anlamsızdır (ör. "%10 yılda"). Trigram ($K = 2$) modelinde ardışık üçlüler daha anlamlıdır (ekrandan, 02:11:00).
- Ardışık geçme yerine aynı dokümanda geçme (ekrandan, 02:17:35)
  - Olasılık hesabında "A'dan sonra B kaç kez geldi" yerine "A ile B kaç dokümanda birlikte geçti" kullanılabilir.
  - Frekansı çok yüksek kelimeler (stop word) atılmalıdır; yoksa her kelimeye en benzer kelimeler onlar olur.
  - $K = 1$, $t = 15$ ile üretilen dizi ("faiz oranı yüksek yönetim kurumsal yönetim kurulu genel 2 satış 5 enflasyon merkez cari kredi …") cümle olarak anlamsızdır, ama aynı konudaki kelimeleri sıralar. "Faiz"e en benzeyen kelimeler: merkez, kredi, bankası, oranı, cari.
  - Sonuç: cümle üretimi için iyi değildir; benzer anlamlı kelimeleri bulmak için kullanılabilir.
- Kelime benzerliği (ekrandan, 02:19:10)
  - Karakter benzerliği (edit distance, Levenshtein): bir kelimeyi diğerine dönüştürmek için gereken düzenleme sayısı. Karakter benzerliği anlam benzerliğini ölçmez.
  - Anlam benzerliği: "Cimbom" ile "Galatasaray" karakter olarak hiç benzemez ama anlamca benzerdir.
- Saklı Anlam İndeksleme (Latent Semantic Indexing, LSI) (ekrandan, 02:20:30)
  - Kelimelerin ardındaki saklı kavramları ortaya çıkarıp dokümanları bu kavramlar uzayında temsil etmek.
  - Terim-doküman matrisi A ($m \times n$) tekil değer ayrışımı (SVD) ile üç matrise ayrılır: $A = U\Sigma V^T$.
  - İlk k bileşen alınarak $\hat{A}_k = U_k \Sigma_k V_k^T$ elde edilir: U'nun ilk k sütunu, Σ'nın ilk k satır ve sütunu, V^T'nin ilk k satırı.
  - Mantığı PCA ile aynıdır: ilk bileşenler en çok bilgiyi taşır, sondakiler az bilgi taşır ve atılabilir. Örneğin 5000 terimle temsil edilen dokümanlar 100 boyuta indirilebilir; "Galatasaray" ve "Cimbom" gibi farklı terimler aynı kavrama düşer.
  - Küçük örnek (ekrandan, 02:24:40): 9 kelime (kedi, miyav, süt, fare, köpek, havla, kemik, hayvan, tüy), 8 doküman (ilk 4'ü kedi, son 4'ü köpek sınıfından). Matris terim-doküman hâline getirilir, SVD uygulanır, $r = 5$ boyut alınır, sonuç hiyerarşik kümelemeyle çizilir (ekrandan, 02:27:00).
  - Sınıf bilgisi hiç verilmediği hâlde dendrogramda 1, 4, 2, 3 numaralı dokümanlar bir grupta, 6, 8, 5, 7 numaralı dokümanlar öteki grupta toplanır.
  - Kelime vektörü bulmak için word2vec, FastText gibi yöntemler zorunlu değildir; LSI gibi klasik yöntemler de vardır.

Hocanın Özellikle Vurguladığı Kısımlar

- Gerçek veri kümeleri kirlidir
  - Sunumlarda yaşanan kodlama ve Türkçe karakter sorunları üzerine hoca, gerçek veri kümelerinin böyle olduğunu, bu veri kümesinin aslında çok temiz sayıldığını söyledi.
- FastText alt dizgilere bakar
  - "Altın"a en yakın kelimeler arasında "alt, altı" çıkması FastText'in karakter n-gram kullanmasındandır. word2vec bu tür kelimeleri bulmaz.
- Cümle olasılığı ve sonraki kelime tahmini
  - Dil modelinin iki temel işi ve uygulama alanları (çeviri, yazım düzeltme, konuşma tanıma, metin üretme) ayrıca soruldu ve tekrar edildi.
- Ardışık geçme ile aynı dokümanda geçme farkı
  - Aynı dokümanda geçme bilgisi cümle üretmeye yaramaz, ama anlamca benzer kelimeleri bulmaya yarar; ileride kelime vektörlerinde bu fikir kullanılacak.
- LSI'da sınıf bilgisi verilmez
  - Algoritmaya yalnız terim-doküman matrisi verilir. Aynı sınıftaki dokümanların birbirine yakın çıkması yalnız içlerinde geçen kelimelerden kaynaklanır.
- Karakter benzerliği anlam benzerliği değildir
  - Edit distance "Cimbom" ile "Galatasaray"ın benzer olduğunu yakalayamaz.

Kısa Tekrar Notları

- Dil modeli: sonraki kelimeyi tahmin eder, cümle olasılığını hesaplar.
- K: kaç önceki kelimeye bakıldığı. Metin üretirken yalnız önceki kelimeler kullanılabilir.
- Unigram üretiminde ikililer, trigram üretiminde üçlüler anlamlıdır.
- Aynı dokümanda birlikte geçme: stop word atılmalı; cümle üretimine değil, benzer kelime bulmaya yarar.
- Edit distance (Levenshtein): karakter benzerliği; anlamı ölçmez.
- LSI: $A = U\Sigma V^T$, ilk k bileşenle $\widehat{A}_k = U_k\Sigma_k V_k^T$.
- U: kelime-kavram, Σ: tekil değerler (köşegen), V: doküman-kavram.
- LSI, PCA mantığıyla en çok bilgi taşıyan boyutları tutar.
- Kedi/köpek örneğinde etiket verilmeden dokümanlar sınıflarına göre kümelendi.
- Sunumlardaki fikirler: graf veri tabanında yol bulma, regex + word2vec ile bilgi çıkarımı, cümle zenginleştirme, kullanıcı oylarıyla ilişki doğrulama, WordNet ile kapsayıcılık ölçme, PCA ile görselleştirme, FastText ile kelime temsili.

Detaylı Açıklamalar

- Dersin ilk bölümünde öğrenciler birinci ödevlerini sundu. Ödevlerin ortak girdisi, sınıfın önceki haftalarda doldurduğu Türkçe hayat bilgisi veri tabanıydı: her isim ve fiil için "kim kullanır, nerede bulunur, ham maddesi nedir, rengi nedir, kimle neyle yapılır, nasıl yapılır, ne olunca yapılır" gibi sorulara verilmiş kısa cevaplar. Sunumlar bu verinin hem kullanılabileceğini hem de kusurlarını gösterdi. Graf veri tabanı yaklaşımında kelimeler düğüm, ilişki türleri kenar olarak saklandı ve iki kelime arasındaki yollar Cypher sorgusuyla bulundu. Yön belirtilmeden yapılan aramada yollar aynı kalıpları tekrarladı; anlamsız cevaplar ("ateş etmek nasıl yapılır: kırmızı" gibi) yolu yanlış yerlere saptırdı. Bilgi çıkarımı yapan sistem, önce veri tabanından sözlük tabloları üretti; cümledeki kelime sözlükte yoksa Türkçe eklere dayalı regex şablonları, o da yetmezse word2vec kosinüs benzerliği kullandı. Kelime benzerliği adımında anlamsız eşleşmeleri elemek için küçük bir varsayılan sıfat listesiyle süzme yapıldı. "Kim" sorusunun sonuçları en kötü olandı, çünkü ilgili tabloya fiiller de karışmıştı.
- Cümle zenginleştirme sunumunda kullanıcıdan alınan cümle Zemberek ile çözümlendi ("ali kahve içti" için kahve: Noun, iç: Verb+Past+A3sg) ve isim/fiillerin hayat bilgisindeki ilişkili kelimeleri cümleye eklendi (ekrandan, 00:50:00). Hoca bunun cümledeki kelimeleri değiştirmediğini, cümleye uygun olabilecek ek ifadeler koyarak cümleyi uzattığını özetledi ve birden fazla ilişkiyi tek cümleye koymak yerine ayrı ayrı üretmenin daha iyi olabileceğini söyledi. İki sunum, kullanıcıdan alınan evet/hayır cevaplarıyla ilişkilerin güvenilirliğini ölçmeye çalıştı; birinde soru-cevap çiftinin görseli gösterildi, ötekinde yalnız

ilişki metni. Sayaç tabanlı yöntemde olumlu ve olumsuz oyların birbirini götürmesi, kaç kişinin oy verdiği bilgisini kaybettirir.

- Değerlendirme sunumunda doğruluk, rastgele seçilen 100 ilişkinin elle işaretlenmesiyle ölçüldü (isimlerde %87, fiillerde %96). Kapsayıcılık için iki yol izlendi: kelime listesinin başka sözlüklerde (İngilizce WordNet ve Zemberek sözlüğü) ne kadarının bulunduğu, ve insanların bir kavram için ürettiği ilişkilerin ne kadarının veri tabanında olduğu. WordNet'ten eş ve zıt anlamlılar da çekildi (ör. "date" için "day_of_the_month", Türkçeye geri çevrilince "broşür" için "kitapçık"), ama zıt anlamlıların çoğu boş geldiği için veri setine eklenmedi (ekrandan, 01:20:00). Çeviri hataları ve API istek sınırı sonuçları etkiledi.
- Görselleştirme sunumunda bir kelimenin 100 boyutlu vektörü, en sık 100 kelimeyle ağaçtaki komşuluğuna göre puanlandı. Hoca, matrisin i, j elemanının i'inci kelimenin en sık j'inci kelimeyle ilişkisinin gücü olduğunu teyit ettirdi. PCA ile iki boyuta indirilen haritada yiyecekler, yapı malzemeleri, elektronik eşyalar yan yana düştü. Hoca farklı boyut indirgeme yöntemleri ya da daha çok sık kelime (ör. 500) denenebileceğini söyledi. FastText sunumunda veri tabanı "kelime ilişki cevap" dizilerine çevrilerek bir derlem kuruldu ve skip-gram eğitildi; "kömür"e kül, soba, yakıt, ocak; "plastik"e elastik, lastik, silikon gibi kelimeler yakın çıktı, "kedi" için sonuçlar zayıftı. Hoca, verinin yalnız yaklaşık 500 isim ve 500 fiil için toplandığını düşününce sonuçların iyi sayılabileceğini söyledi.
- Ders bölümüne geçilince geçen haftanın dil modelleri tekrar edildi. Bir cümlenin olasılığını bilmek, birden fazla aday arasında (çeviri, yazım düzeltme, sesten metne) en olasısını seçmeyi sağlar. Sonraki kelimeyi tahmin edebilmek ise metin üretimini sağlar: tahmin edilen kelime diziye eklenir ve bir sonraki tahmin onunla yapılır. K büyüdükçe üretilen metin daha anlamlı olur, ama K'yi büyütmenin geçen hafta konuşulan bedelleri vardır. Bir öğrenci, K sabitken daha önce üretilen bir kelimenin sonradan gelen kelimelere göre uygun olup olmadığını kontrol edip gerekirse oradan yeniden üretmeyi önerdi; hoca böyle bir kontrol mekanizmasının kurulabileceğini ve daha kaliteli metin verebileceğini söyledi.
- Ardından olasılık hesabında ardışık geçme yerine aynı dokümanda geçme kullanmanın etkisi gösterildi (ekrandan, 02:17:35). Birlikte geçme sayıları, yan yana olmasalar da aynı dokümanda bulunan kelimeleri sayar. Bu durumda üretilen dizi dilbilgisel değildir ama hep aynı konuya (ekonomi: faiz, merkez, kredi, banka, cari) ait kelimelerden oluşur. Yani birlikte geçme, kelimelerin anlamca ilişkisini yakalar; bu fikir ileride kelime vektörlerinde kullanılacaktır.
- Kelime benzerliği iki türlüdür. Karakter benzerliği edit distance (Levenshtein) ile ölçülür; iki kelime arasındaki uzaklık ya da bir kelimeye belli uzaklıktaki kelimeler bulunabilir. Ama "Cimbom" ile "Galatasaray" arasında ortak karakter dizisi neredeyse yoktur, oysa anlamca benzerdirler. Anlam benzerliğini yakalamanın klasik yollarından biri Saklı Anlam İndeksleme'dir (LSI).
- LSI, terim-doküman matrisini SVD ile $A = U\Sigma V^T$ biçiminde çarpanlara ayırır (ekrandan, 02:20:30). Dokümanlar başlangıçta terim sayısı kadar boyutlu bir uzaydadır (ör. 5000 terim, 100 doküman). PCA'de olduğu gibi ilk bileşenler verideki bilginin büyük kısmını taşır; bu yüzden U'nun ilk k sütunu, Σ'nın ilk k tekil değeri ve V^T'nin ilk k satırı tutulup gerisi atılır. Böylece dokümanlar çok daha düşük boyutlu bir kavram uzayında temsil edilir ve farklı yazılan ama aynı kavramı anlatan terimler aynı boyutlarda birleşir.
- Slayttaki MATLAB örneğinde (ekrandan, 02:24:40) 8 kısa doküman 9 kelimeyle temsil edildi (`D` 8×9). `D=D'` ile terim-doküman hâline getirildi, `[U,S,V]=svd(D)` uygulandı. Kod yorumlarına göre U 9×9 kelime-kavram, S 9×8 tekil değerler, V 8×8 doküman-kavram matrisidir. Tekil değerler 2.4893, 2.0216, 1.8073, 1.3486, 1.2349, 0.8247, 0.5943, 0.2694'tür (ekrandan, 02:27:00; python ile doğrulandı). `r=5` alınarak yeni doküman temsili hesaplandı ve `linkage` + `dendrogram` ile çizildi. Dendrogramda 6-8 en önce birleşir, 5 ve 7 onlara katılır; öteki tarafta 1-4 birleşir, 2 ve 3 onlara katılır. Böylece etiket verilmeden kedi dokümanları (1-4) ve köpek dokümanları (5-8) ayrı kümelere düştü.
- Ders, kavramsal ağaç (taksonomi) ile anlamsal benzerlik slaytında (bağ sayma ve ortak bilgi yaklaşımları) durdu; bu konular işlenmedi (ekrandan, 02:28:55). Hoca, sabit kelime vektörlerinin bulunduğu anlamsal uzaylar bölümünün sonraki derste tamamlanacağını, ardından WordNet tabanlı benzerlik ölçülerine, kelime vektörü yöntemlerine ve sinirsel dil modellerine (word2vec, FastText) geçileceğini söyledi.

- **Not:** İsterseniz bu dersin altyazı (.srt) dosyasını Gemini Notebook gibi bir yapay zeka aracına yükleyerek ders hakkında daha detaylı soru-cevaplar yapabilir ve dersi verimli çalışabilirsiniz.