# DPO Ensembles

1st Anıl Şanlı
*Fen Bilimleri Enstitüsü*
*Yıldız Teknik Üniversitesi*
İstanbul, Türkiye
anil.sanli@std.yildiz.edu.tr

***Abstract*—Büyük Dil Modellerinin (LLM) belirli alanlarda özelleştirilmesi modelin diğer alanlarda performansını kaybetmesine neden olabilmektedir. Bu çalışmada hem bu sorunu aşmak hem de kolektif öğrenmenin toplu öğrenmeye göre kıyaslamasını yapmak için Doğrudan Tercih Optimizasyonu (DPO) tabanlı bir yaklaşım üzerinden deneyler yapılmıştır. Çalışmada Llama-3 mimarisi üzerinde QLoRA bağımsız uzmanlar eğitilmiş, modeller birleştirilerek kolektif model elde edilmiş ve toplu eğitime göre kıyası yapılmıştır. Deneysel sonuçlar kolektif modelin bağımsız uzmanların aksine tüm alanlarda daha tutarlı ve yüksek performans gösterdiğini, toplu eğitim modeline göre ise çoğunlukla daha iyi performans gösterdiğini sunmuştur. Model birleştirme yöntemi hem yüksek performanslı hem de sürdürülebilir bir yöntem olarak öne çıkmıştır.**

***Index Terms*—büyük dil modelleri, kolektif öğrenme, doğrudan tercih optimizasyonu, model birleştirme**

## I. Giriş - Problem Tanimi

Büyük Dil Modelleri (LLM) doğal dil işleme görevlerinde başarı sergilese de kullanıcı niyetlerine uygun yanıtlar üretebilmeleri için bazı süreçlere ihtiyaç duyarlar. Bu bağlamda Doğrudan Tercih Optimizasyonu (DPO - Direct Preference Optimization) yaklaşımı sunulmaktadır. DPO karmaşık bir ödül sistemi kurmaya gerek olmadan çalışan bir yaklaşımdır. DPO'nun temel mantığı modele aynı istem için biri tercih edilen (chosen) diğeri reddedilen (rejected) olarak verilen iki farklı cevaptan hangisinin daha iyi olduğunu doğrudan öğretmektir. Böylece model insan tercihlerini daha hızlı, kararlı ve düşük maliyetle öğrenebilir.

Modeller belirli bir alan özelinde eğitildiğinde diğer alanlardaki başarısı düşebilir. Bu çalışmada farklı konularda içeren setler ile tek bir model eğitilmek yerine bu konular için ayrı ayrı uzman modeller eğitilmiş ve daha sonra bu uzman modeller birleştirilerek bir kolektif model oluşturulmuştur. Aynı zamanda toplu eğitim yapıldığında aynı test setleri üzerinde başarının nasıl değiştiğiyle ilgili deneysel çalışma yapılmıştır.

Proje kapsamında geliştirilen her uzman model ilgili konuda 2000 eğitim verisi kullanılarak eğitilmiş ve 500 test verisi kullanılarak test edilmiştir.

## II. Kullanilan Veri Seti ve Metodolojiler

Bu bölümde çalışmada kullanılan veri setinden, baz alınan büyük dil modelinden, uygulanan eğitim stratejilerinden ve model birleştirme tekniğinden bahsedilecektir.

### A. Veri Seti

Çalışmada HuggingFace üzerinde açık olarak paylaşılmış *yusufbaykaloglu/Turkish-STEM-DPO-Dataset* veri seti kullanılmıştır. Bu veri seti matematik, fizik ve programlama konularında çeşitli alt başlıklarda ve zorluk seviyelerinde istem ve bu istemlerin tercih edilen ve reddedilen cevaplarından oluşmaktadır. Veri setinde detay olarak *chosen_score, rejected_score, margin, topic, subtopic, difficulty, chosen_tier, rejected_tier* gibi alanlar mevcuttur. Veri setinde her bir konuda 5000'in üzerinde kayıt, 18 konu ve 140'ın üzerinde alt konu bulunmaktadır.

### B. Model

Çalışmada temel model olarak Llama-3 mimarisi üzerinde inşa edilmiş ve Türkçe metin oluşturma görevleri için tasarlanmış 8 milyar parametreli *ytu-ce-cosmos/Turkish-Llama-8b-DPO-v0.1* modeli kullanılmıştır.

### C. Eğitim Aşamaları

Temel model matematik, fizik ve programlara konularından seçilmiş 2000'er adet soru ile ayrı ayrı eğitilerek 3 bağımsız uzman model (adaptör) oluşturulmuştur. Eğitim esnasında hesaplama maliyetlerini düşürmek ve modelin genel yeteneklerini çoğunlukla koruyabilmek adına QLoRA (Quantized Low-Rank Adaptation) stratejisi uygulanmıştır. Bu yöntemle ana modelin ağırlıkları korunmuş ve modele küçük adaptör katmanları eklenerek bu katmanlar eğitilmiştir.

Ayrıca kıyaslama yapabilmek için aynı 6000 kayıt kullanılarak temel model tek seferde eğitilmiştir.

Eğitim hiperparametreleri olarak LoRA konfigürasyonunda Rank değeri 16, Alpha değeri 32 olarak seçilmiş ve aşırı öğrenmeyi engellemek adına 0.05 oranında Dropout uygulanmıştır. Eğitimde kullanılan öğrenme oranı (learning rate) 1e-6'dır.

Eğitim süreci boyunca modellerin öğrenme dinamikleri Şekil 1'de gösterilmiştir. Daha az veri büyüklüğüyle eğitilen uzman modeller 250 adımda eğitilirken toplu model 700 adımda eğitilmiştir. Tüm modellerin kayıp değerleri şekildeki grafikte gösterilmiştir.

### D. Model Birleştirme

Eğitilen bağımsız konu uzman adaptörleri Doğrusal Model Birleştirme (Linear Model Merging) yöntemi ile birleştirilmiştir. Matematik, fizik ve programlama adaptörleri için birleştirme katsayıları eşit olarak belirlenmiştir. Böylece her uzman adaptörün yetkinliğinin kolektif modele eşit olarak yansıması sağlanmıştır.

Birleştirme işlemi Eşitlik 1 ile ifade edilebilir:

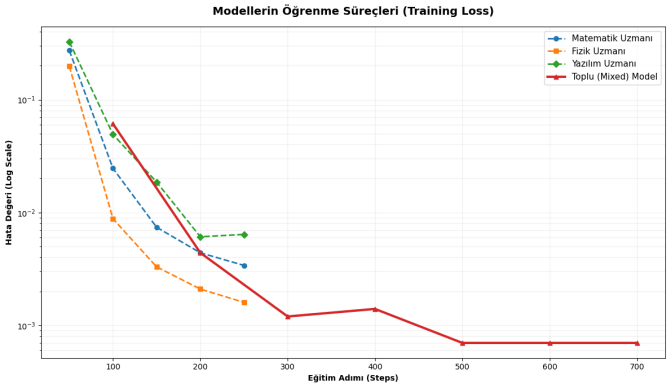



Fig. 1. Modellerin Eğitim Süreçleri Boyunca Kayıp (Training Loss) Değişimleri

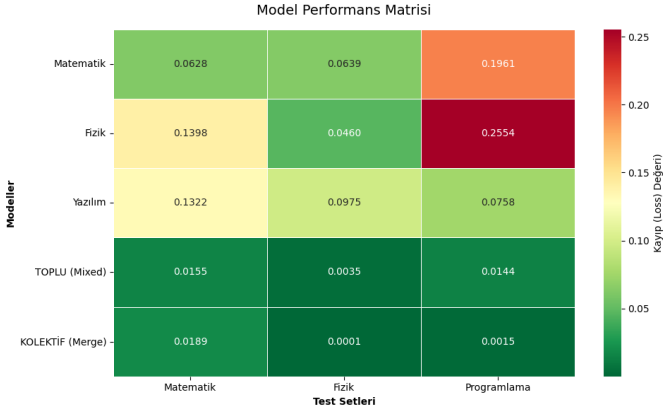



Fig. 2. Model Performans Karşılaştırmaları

$$\theta_{kolektif} = \theta_{base} + \sum_{i \in \{math, phys, prog\}} w_i \cdot \theta_i \qquad (1)$$

## III. Deneyler ve Sonuçlar

Bu çalışmada modellerin performansı eğitim setinden tamamen ayrılmış ve modellerin daha önce görmediği her bir konudan 500'er soru, toplamda 1500 soru, içeren test kümelerinden ölçülmüştür. Modellerin başarısı kayıp değerleri üzerinden analiz edilmiştir.

Yapılan testlerde uzman modellerin kendi alanlarında başarı gösterirken diğer alanlarda başarısız olduğu, yani eğitim seti harici diğer alanları unutmaya başladığı gözlemlenmiştir. Bunun kıyası da temel modelle yapılabilir. Örneğin matematik uzman modeli kendi alanındaki test setinde 0.06 seviyesinde düşük bir kayıp değeri sergilerken programlama setinde bu hata oranı 0.20 seviyelerine kadar çıkmıştır. Bu durum bağımsız modellerin kendi alanları dışındaki sorulara daha tutarsız tahmin yaptığını göstermektedir.

TABLE I
Modellerin Farklı Test Kümeleri Üzerindeki Kayıp (Loss) Değerlerinin Karşılaştırılması

| Model | Matematik Testi | Fizik Testi | Yazılım Testi |
|---|---|---|---|
| Matematik | 0.063 | 0.064 | 0.196 |
| Fizik | 0.140 | 0.046 | 0.255 |
| Programlama | 0.132 | 0.098 | 0.076 |
| **Kolektif (Merge)** | 0.019 | **0.000** | **0.002** |
| Toplu (Mixed) | **0.015** | 0.004 | 0.014 |

Buna karşın kolektif model tekil uzmanların aksine ve beklenildiği gibi tüm test alanlarında dengeli ve yüksek performans sergilemiştir. Şekil 2 ve Tablo 1'de sunulan sonuçlara göre kolektif model ve toplu eğitimin gerçekleştiği model ayrı modellere göre tüm alanlarda daha iyi bir performans sergilemiş, bu iki model arasında ise matematik testinde toplu model daha yüksek performanslıyken fizik ve programlama konularında kolektif model daha yüksek başarı sergilemiştir.

## IV. Tartışma

Çalışmada elde edilen bulgular büyük dil modellerinde model birleştirme yönteminin bir modeli topluca eğitmeye göre çoğu senaryoda daha iyi performans gösterdiğini sunmaktadır. Elde edilen sonuçlar incelendiğinde kolektif modelin tekil uzmanların yaşadığı diğer konuları unutma problemini aştığı ve toplu modele göre test edilen üç konunun ikisinde daha iyi başarı sağladığı görülmektedir. Bu durum farklı veri setleriyle eğitilmiş bağımsız modellerin birbirlerinin eksiklerini kapatarak birleşebildiğini göstermektedir.

Ayrıca yeni bir uzmanlık alanı eklenmek istediği zaman toplu eğitim yaklaşımının tüm veriyi yeniden eğitim sürecine sokması gerekirken önerilen birleştirme yönteminde sadece yeni alanın eğitilmesi ve mevcut yapıyla birleştirilmesi yeterlidir. Bu açıdan da model birleştirerek kolektif model elde etmenin daha sürdürülebilir bir yöntem olduğu söylenebilmektedir.

Sonuç olarak model birleştirme tekniklerinin hem hesaplama maliyetlerini en aza indirmesi hem de modele esneklik katması nedeniyle güçlü bir alternatif mimari olduğunu söyleyebiliriz.