Ders 13 Çalışma Özeti

Ders 13 Çalışma Özeti

Genel Konular

- Dersin tarihi 7 Ocak 2021 Perşembe, dönemin son haftası. Zoom üzerinden yapıldı. Kayıt yaklaşık 4 saat 45 dakika sürüyor.
- Bu derste konu anlatılmadı. Bütün kayıt dönem projesi sunumlarından oluşuyor.
  - Gruplar bekleme odasına (waiting room) alındı. Her grup sırayla toplantıya alınıp projesini sundu.
  - Sunum düzeni: önce öneri (proposal) belgesine göre amaç, sonra çalışan demo, sonra kodların anlatımı.
- Sunulan projeler dersin dört ana konusuna göre gruplanabilir:
  - **Web tarayıcı (crawler) uygulamaları:** Birden fazla e-ticaret sitesinden ürün verisi toplayıp tek sayfada gösterme ve filtreleme.
  - **Sınıflandırma projeleri:** Haber başlığı sınıflandırma, kredi kartı sahtecilik (fraud) tespiti, blog sayfası olup olmadığını belirleme, yorum kaldırma tahmini.
  - **Öneri sistemleri (recommendation systems):** Film, şarkı, ürün ve akademik makale başlığı önerisi.
  - **Fikir madenciliği (opinion mining) ve duygu analizi (sentiment analysis):** Tweet duygu analizi, haber metinlerinde taraf belirleme, ürün yorumu analizi, emoji tabanlı duygu kümeleme.

Hocanın Özellikle Vurguladığı Kısımlar

- **Grup üyelerinin hepsi sunumda bulunmalı.** Bir üyenin "çalışıyorum, katılamayacağım, arkadaşım sunsun" diye yazdığı grubun sunumu kabul edilmedi. İki üye birlikte bekleme odasına geldiğinde yeniden sunum hakkı verileceği söylendi.
- **Ekran paylaşımı yapılabilmeli.** Teknik sorunu önceden çözmek grubun sorumluluğu.
- **Crawler projelerinde filtreleme şart.** Birden fazla siteden toplanan veri kategoriye ve fiyata göre süzülüp sıralanabilmeli.
  - Hocanın örneği: E-ticaret sitesinde bütün ürünler yerine yalnız Nike ürünlerini ya da yalnız 43 numara ayakkabıları görmek istersiniz.
  - Verileri yalnız CSV'ye yazıp filtrelemeyi arayüze koymayan grubun projesi eksik bulundu. Hoca, projeyi kabul ederken istediğinin bu olmadığını söyledi.
- **Öneri sistemlerinde değerlendirme (evaluation) gerekli.** Yalnız benzerlik skorlarını listelemek yeterli değil. Yapılan önerilerin iyi mi kötü mü olduğu bir değerlendirme yöntemiyle gösterilmeli.
- **Sınıflandırma projelerinde en az üç farklı algoritma.** Kendi etiketli verinizle üç ayrı model eğitilip karşılaştırılmalı. Hazır bir kütüphane fonksiyonuyla (ör. TextBlob'un duygu fonksiyonu) sonuç almak yeterli değil.
  - Az veriyle bile etiketleyip model kuran gruplar var.
  - Hoca derste işlenen tekniklerin kodun içinde görülmesini istiyor.
- **Zaman yönetimi:** Proje iki ay önceden verildi ve öneri belgesi istendi. Öneri belgesinde ne zaman, neyin yapılacağı yazılıyordu. Hoca "başka derslerin projeleri vardı" gerekçesini kabul etmedi. Bunun nota yansıyacağını söyledi.
- **Teslim:** Kodlar Google Drive bağlantısıyla, readme dosyasıyla birlikte gönderilmeli. Bazı gruplar GitHub ve Heroku bağlantısı gönderdi. Hoca kodun proje olarak gönderilmesini istedi.
- Bitirme projesinden uyarlanan projeler de sunuldu. Hoca bunları biliyordu.

- Sunumun sonunda hoca final sınavı haftasına geçildiğini söyledi ve sınavlarda başarılar diledi.

Kısa Tekrar Notları

- Proje değerlendirmesinde bakılanlar:
  - Öneri belgesiyle uyum.
  - Çalışan bir kullanıcı arayüzü ve canlı demo.
  - Kodların anlatılması ve sorulara cevap.
  - Derste işlenen tekniklerin (TF-IDF, sınıflandırıcılar, öneri yöntemleri, crawler) kullanılması.
  - Sonuçların değerlendirilmesi: sınıflandırmada precision, recall, F1, accuracy; öneride bir başarı ölçütü.
  - Teslim edilen paketin readme ile başkasının bilgisayarında çalışabilmesi.
- Sunumlarda geçen yöntemler:
  - Scrapy ve Selenium ile tarama, Django ya da React ile arayüz, MongoDB ya da Firebase ile saklama.
  - TF-IDF vektörleri ve kosinüs benzerliği (cosine similarity) ile isim tabanlı ürün önerisi.
  - Pearson korelasyonu ile kullanıcı tabanlı işbirlikçi filtreleme (user-based collaborative filtering), MovieLens veri seti.
  - scikit-learn ile Decision Tree, Random Forest, Naive Bayes, Logistic Regression, SGD.
  - Word2Vec, LSTM, metin vektörleştirme (vectorizer).

Detaylı Açıklamalar

Örnek crawler projesi akışı

- Hedef: Hepsiburada ve n11'den dizüstü bilgisayarların markasını, fiyatını, özelliklerini ve satış bağlantısını toplamak.
- Selenium tarayıcıyı sürekli çalıştırdığı için yavaş bulundu. Scrapy'ye geçildi.
- Scrapy örümceğinde (spider) başlangıç URL'si, XPath ile fiyat, bağlantı ve özellik alanları tanımlandı. Sayfa numarası artırılarak 50 sayfa tarandı.
- Fiyat metni ondalık sayıya çevrildi. Yoksa fiyat aralığına göre süzme çalışmıyordu.
- Sonuçlar CSV'ye yazıldı ve Django ile bir veri tablosunda gösterildi. Tabloda en düşük ve en yüksek fiyat, marka ve özellik (ör. 4 GB) ile arama yapılabiliyor. Satırdaki bağlantı ürünün satıldığı siteye götürüyor.

Örnek ürün takip ve öneri projesi

- Kullanıcı Google hesabıyla giriş yapıyor. Her kullanıcı için Firebase'de bir tablo tutuluyor.
- Kullanıcı ürün bağlantısını ekliyor. Sistem ürünün adını, fiyatını ve fotoğrafını tarayıp çekiyor. Kullanıcı bir hedef fiyat ve not girebiliyor.
- Öneri: Birkaç sitenin indirimli ve çok satan ürünleri taranıyor. Ürün adları TF-IDF ile vektörleştiriliyor. Eklenen ürüne kosinüs benzerliği en yüksek ürün öneriliyor.
- Hedef fiyata ulaşınca bildirim gönderme özelliği tamamlanamadı.

Örnek haber sınıflandırma projesi

- Bir haber veri setinin başlıkları 5 kategoriye ayrıldı. Eğitim verisi dengeli olacak şekilde örneklendi.
- Decision Tree, Random Forest ve Naive Bayes eğitildi. Doğruluklar sırasıyla yaklaşık %58, %67 ve %73 çıktı.
- Twitter API ile iki haber hesabının son tweetleri çekildi. Resim bağlantıları düzenli ifadeyle (regex) temizlendi ve model her tweete kategori tahmin etti.
- Grup, veri setinin 2017'ye kadar olduğunu fark etti. COVID ile ilgili tweetler ve sonraki siyasi olaylar doğru sınıflanamıyordu. Bu, eğitim verisinin zamanla eskimesine (concept drift) güzel bir örnek.

Örnek film öneri projesi

- MovieLens veri setinde yaklaşık 20 milyon puan ve 140 bin kullanıcı var.
- En çok puan veren 100 kullanıcı alındı. Girilen kullanıcı puanlarıyla Pearson korelasyonu hesaplandı ve en benzer 50 kullanıcı seçildi.
- Her film için benzerlikle ağırlıklandırılmış puanlar toplandı ve benzerliklerin toplamına bölündü. En yüksek ortalama skora sahip 10 film önerildi.
- Grup yöntemi "content-based" diye adlandırdı. Anlatılan yöntem kullanıcı tabanlı işbirlikçi filtrelemedir.

Ders sonrası notlar

- **Yöntem adı:** Film öneri grubunun anlattığı yöntem (benzer kullanıcıların ağırlıklı puan ortalaması) içerik tabanlı (content-based) değil, kullanıcı tabanlı işbirlikçi filtrelemedir (user-based collaborative filtering). İçerik tabanlı yöntem filmlerin özelliklerine (tür, oyuncu, etiket) bakar.
- **Öneri değerlendirmesi:** Hocanın istediği değerlendirme için yaygın ölçütler: bekletilen (hold-out) puanlarda RMSE ya da MAE, ilk k öneride precision@k ve recall@k.
- **Kişisel bilgiler:** Kayıtta öğrencilerin adları, öğrenci numaraları ve ekranlarındaki belgeler görünüyor. Özete bunların hiçbiri alınmadı.

Not: İsterseniz bu dersin altyazı (.srt) dosyasını Gemini Notebook gibi bir yapay zeka aracına yükleyerek ders hakkında daha detaylı soru-cevaplar yapabilir ve dersi verimli çalışabilirsiniz.