Ders 12 Çalışma Özeti

Ders 12 Çalışma Özeti

Genel Konular

- Dersin tarihi 31 Aralık 2020 Perşembe, yılın son günü. Ders Zoom üzerinden yapıldı. Kayıt yaklaşık 2 saat sürüyor.
  - Bu ders büyük ölçüde Türkçe anlatıldı.
- Bağlantı analizinin kısa özeti: merkezilik, prestij, ortak atıf (co-citation), bibliyografik eşleşme (bibliographic coupling), PageRank.
- HITS algoritması (Hypertext Induced Topic Search):
  - Kök küme (root set) ve taban küme (base set).
  - Otorite (authority) ve merkez (hub) skorları.
  - Matris gösterimi ve kuvvet yinelemesi (power iteration).
  - Ortak atıf ve bibliyografik eşleşme matrisleriyle ilişkisi.
  - Avantajları ve dezavantajları.
- Web kullanım madenciliği (web usage mining), kitabın 12. bölümü:
  - Veri kaynakları ve tıklama akışı (clickstream) verisi.
  - Veri hazırlama (data preparation) adımları.
  - Kullanıcı tanımlama (user identification), oturum tanımlama (sessionization), sayfa görüntüleme tanımlama (pageview identification), yol tamamlama (path completion), bölüm tanımlama (episode identification).
  - Olaylar (events) ile tıklama akışının eşleştirilmesi.
  - Kullanıcı işlem veritabanı (user transaction database) üzerinde örüntü keşfi ve modelleme.
- Dönem projesi sunumlarının nasıl yapılacağı.

Hocanın Özellikle Vurguladığı Kısımlar

- PageRank ve HITS 1998'de ortaya çıktı. PageRank Stanford'dan, HITS Cornell'den çıktı. Hoca PageRank'i Google'ın, HITS'i Yahoo'nun kullanmaya başladığını söyledi. PageRank, Google'ın ortaya çıkmasını sağlayan nedenlerden biriydi.
- İki algoritmanın da ilk adımı aynıdır: sorgu, TF-IDF'e göre ters dizin (inverted index) tablosunda aranır ve eşleşen belgeler bulunur.
- PageRank sorgudan bağımsızdır. Örnek: "web data mining" araması.
  - En otoriter sayfa, bu başlıkta bir kitabın sayfasıdır.
  - Ama bu sayfanın PageRank'i düşükse, kelimeleri içeren ve daha popüler sayfalar onu ilk 10 sonucun dışına itebilir.
  - Hocanın ikinci örneği: İkinci Dünya Savaşı ile ilgili, çok kişi tarafından düzenlenen Wikipedia sayfası.
- HITS sorguya bağımlıdır. Sorguya göre küçük bir graf kurar ve onun üzerinde hesaplar.
- İyi otorite, çok sayıda iyi merkezden bağlantı alır. İyi merkez, çok sayıda iyi otoriteye bağlantı verir. İki skor birbirini besler.
- Her sayfanın iki skoru vardır: otorite skoru ve merkez skoru.
- Hocaya göre HITS'in en önemli dezavantajı, hesabın sorgu anında yapılmasıdır.
- **Sınav uyarısı:** Bağlantı analizi bölümündeki her şeyden sorumlusunuz. Bunlar sosyal ağ analizi, merkezilik ve prestij metrikleri, ortak atıf, bibliyografik eşleşme, PageRank ve HITS'tir. Bölüme iyi çalışarak final sınavına gelin.
- **Sınav uyarısı (web kullanım madenciliği):** Oturum oluşturma, kullanıcı tanımlama, oturum tanımlama, eksik URL tamamlama (path completion) ve sezgisel yöntemler (he-

uristics) önemli konulardır. Sınavda karşınıza çıkabilir.
- **Proje sunumu duyuruları:**
  - Sunumlar gelecek hafta, dönemin son haftasında yapılacak.
  - Kameralar açık olacak, ekran paylaşılacak. Proje 5–10 dakikada anlatılacak, kodlar gösterilecek, sorular cevaplanacak.
  - Her projenin bir kullanıcı arayüzü olmalı. Yapılan çalışmayı yapılandırılabilir biçimde gösteren arayüz ne kadar iyiyse o kadar iyi.
  - Sınıflandırıcı kullanan projelerde veri seti seçilebilmeli, sınıflandırıcı seçilebilmeli ve başarısı gösterilebilmeli.
  - Yalnız accuracy ve F1 skoru yazdırmak yeterli değil. Arayüzden tek bir örnek seçilip modelin onu etiketlemesi de gösterilmeli. Örneğin açılır menüden 5 veriden biri seçilir ve model "satın alır / almaz" tahminini yazar.
  - Projeyi bulutta (cloud) çalıştıranlar ek puan alacak.

Kısa Tekrar Notları

- HITS adımları:
  - Sorguyla eşleşen sayfalar kök kümeyi (W) oluşturur.
  - Kök kümedeki sayfaların bağlantı verdiği sayfalar ve kök kümeye bağlantı veren sayfalar eklenir. Sonuç taban kümedir.
  - Taban kümeden bir graf ve komşuluk matrisi L kurulur. $i \to j$ bağlantısı varsa $L_{ij} = 1$, yoksa 0.
- Otorite ve merkez skorları:

$$a(i) = \sum_{j \to i} h(j), \qquad h(i) = \sum_{i \to j} a(j)$$

- Matris gösterimi:

$$a = L^T h, \qquad h = L\, a$$

$$a = L^T L\, a, \qquad h = L\, L^T h$$

- $L^T L$ ortak atıf matrisidir. $L\, L^T$ bibliyografik eşleşme matrisidir.
- İki denklem de kuvvet yinelemesiyle çözülür.
- HITS avantajı: sorguya bağımlı sıralama.
- HITS dezavantajları:
  - Merkez skoru manipülasyona açıktır.
  - Konu kayması (topic drift) olabilir.
  - Hesap sorgu anında yapıldığı için PageRank'ten daha az verimlidir.
- Web madenciliğinin üç kolu:
  - İçerik madenciliği (web content mining): sorgu ile sayfa içeriğini eşleştirme.
  - Yapı madenciliği (web structure mining): bağlantı analiziyle popülerlik.
  - Kullanım madenciliği (web usage mining): kullanıcıların sitedeki davranış örüntüleri.
- Web kullanım madenciliği veri hazırlama sırası:
  - Veri birleştirme (data fusion).
  - Veri temizleme (data cleaning).
  - Kullanıcı tanımlama.
  - Oturum tanımlama.
  - Sayfa görüntüleme tanımlama.
  - Yol tamamlama.
  - Bölüm tanımlama.
  - Veri bütünleştirme (data integration) ve dönüştürme (data transformation).
- Zamana dayalı oturum sezgileri: toplam oturum süresi en fazla 30 dakika. Bir sayfada kalma süresi en fazla 10 dakika.

Detaylı Açıklamalar

HITS'te taban küme nasıl kurulur?

- Kök kümedeki sayfaların içeriği bilinir. Bu yüzden onların verdiği bağlantılar sayfanın köprü bağlantılarından (hyperlink) bulunur.
- Kök kümeye bağlantı veren sayfalar da bulunabilir. Tarama (crawling) sırasında bütün sayfaların içeriği ve bağlantı yapısı veritabanına kaydedilmiştir. Sayfaları yeniden taramaya gerek yoktur.
- HITS bütün web grafı için değil, yalnız bu taban küme için hesaplanır.
- Hoca bir sorgunun taban kümesini yaklaşık 1000–2000 bağlantı olarak düşünmeyi önerdi.

Otorite ve merkez

- **Otorite:** Çok bağlantı alan sayfa. Belirli bir konuda otoriterdir.
- **Merkez (hub):** Çok bağlantı veren sayfa. Bir düzenleyici görevi görür. Örnekler: Yahoo dizini (directory), Open Directory. Bunlar çok sayıda bağlantıyı bir sınıflandırma (taxonomy) içinde sunar.

HITS'in dezavantajları

- **Manipülasyon:** Bir sayfanın verdiği bağlantıları sayfanın yazarı belirler.
  - Yazar iyi otoritelere bağlantı vererek sayfasının merkez skorunu yükseltebilir.
  - Ardından otoriter olmayan sayfalara da bağlantı verirse, onların otorite skorunu yapay olarak artırır.
- **Konu kayması:** Kök kümeden bir adım ileri ve geri gidilince eklenen sayfalar sorgunun konusundan tamamen farklı olabilir. Analiz başka bir konu grubu üzerinde yapılmış olur.
- **Verimlilik:** Ters dizinde arama hızlıdır, çünkü ters dizin bir karma tablo (hash table) gibidir. Ama matris üzerinde kuvvet yinelemesi zaman alır. PageRank skorları önceden hesaplandığı için PageRank'te yalnız yeniden sıralama yapılır.

Web kullanım madenciliğinin amacı

- Web sunucuları kullanıcıların tıklama akışını kayıt (log) dosyalarında tutar.
  - Uygulama sunucusunun (IIS, Tomcat, GlassFish) kendi kayıt dosyası olabilir.
  - Sunucuda çalışan uygulamanın kendi kayıt dosyası olabilir.
- Amaç: çok sayıda kullanıcının kolektif davranış örüntülerini bulmak ve buna göre işlem yapmak.
  - Kampanya oluşturma.
  - Birlikte satılan ürünleri bulma.
  - Kullanıcıların sırayla yaptığı işlemleri bulma.
  - Kullanıcının bir şey almadan çıkıp çıkmayacağını tahmin etme.
- Veri kaynakları:
  - Web sunucusu kayıt dosyaları (en büyük veri bunlardır).
  - Uygulama verisi.
  - Sitenin bağlantı yapısı.
  - Müşteri ilişkileri yönetimi (CRM) gibi eski (legacy) operasyonel veritabanları.
- Bu kaynakların hepsi her zaman bulunmayabilir. Bulunanlar tek bir işlem veritabanında bütünleştirilmelidir.

Bir kayıt satırından ne öğrenilir?

- Her satır bir HTTP isteğidir (request).
- İsteğin tarihi ve saati.
- İsteğin geldiği sunucu ve istenen sayfa. Örnek: `/classes/cs589/papers.html`.
- Yönlendiren sayfa (referrer): kullanıcının hangi sayfadaki bağlantıya tıklayarak geldiği.
- Kullanıcının işletim sistemi, sürümü, tarayıcısı ve tarayıcı sürümü (user agent).
- IP adresi. Statik ya da dinamik olabilir.
- Tarayıcı çerezlere (cookie) izin veriyorsa çerezdeki kullanıcı kimliği (user ID). Kullanıcı tekrar geldiğinde tanınır.

- Oturum kimliği (session ID). Kullanıcının kısa bir zaman dilimindeki hareketleri bununla izlenir.

Kullanıcı işlem veritabanı

- Birliktelik kuralı madenciliği (association rule mining) ve sıralı örüntü madenciliği (sequential pattern mining) konularındaki işlem veritabanına benzer.
- Her satır bir kullanıcıdır. Bir sütunda kullanıcı kimliği, diğerinde kullanıcının sırayla yaptığı etkinlikler oturum bazında tutulur.

Veri temizleme

- Analiz hedefiyle ilgisi olmayan kayıtlar çıkarılır.
- Arama motoru tarayıcılarının (Googlebot, MSNbot gibi) bıraktığı istekler çıkarılır.
- Hatalı istekler çıkarılır.

Kullanıcı tanımlama

Yöntem	Avantaj	Dezavantaj
Çerez (cookie)	Tekrar gelen kullanıcı izlenebilir	Kullanıcılar çerezleri çoğu zaman engeller
Oturum açma (login)	Hangi cihaz ve tarayıcıdan gelirse gelsin izlenir	Herkes oturum açarak gezinmez
Yazılım ajanı (software agent), ör. mobil uygulama	Kullanıcı rahatça izlenir	Kullanıcılar uygulama indirmek istemeyebilir
Gömülü oturum kimliği (embedded session ID)	Tarayıcının engellemesi kolay değil	Yalnız tek oturum izlenir, farklı zamanlardaki ziyaretler ilişkilendirilemez
IP + kullanıcı ajanı (user agent)	Ek bilgi gerektirmez	%100 doğru değil, dinamik IP'de bozulur

- E-ticaret sitelerinin çoğu satın almaya kadar oturum açmayı zorunlu tutmaz. Bazıları üye olmadan satın almaya da izin verir.
- IP + ajan yönteminde IP, işletim sistemi ve sürümü, tarayıcı ve sürümü birleştirilip tek bir kimlik yapılır.
  - Kafe gibi ortak ağlarda IP sürekli değişir. Kullanıcı tanınamaz.
  - Evden statik IP ve tek bilgisayarla bağlanan kullanıcı tanınabilir.
- Hocanın örneği: Kayıtlarda çerez, oturum ve giriş bilgisi yok. Bu yüzden IP + ajan kullanıldı. IE 5 / Windows 2000 ile gelen bir IP birinci kullanıcı, IE 6 / Windows XP ile gelen başka bir IP ikinci kullanıcı oldu.

Oturum tanımlama

- İsteklerde gömülü oturum kimliği varsa gerçek oturumlar doğrudan bulunur. En iyi durum budur.
- Yoksa sezgisel yöntemler kullanılır.
- **Zamana dayalı sezgiler:**
  - Araştırmalara göre bir oturum ortalama 30 dakika sürer. Bu değer siteye göre ayarlanabilir. E-ticarette daha kısa, metin ağırlıklı sitelerde daha uzun olabilir.
  - İlk istekten başlayarak 30 dakika içindeki bütün istekler bir oturumdur.
  - Bir sayfada 10 dakikadan uzun kalınırsa oturum orada bitirilir. Sonraki istek yeni oturumu başlatır.
  - Örnek: İlk istek 0:01'de geldi. 0:31'e kadar olanlar 1. oturum. Sonraki istek 1:15'te geldi ve 2. oturumu başlattı.
- **Gezinmeye dayalı sezgi:**
  - Hoca şöyle anlattı: İlk istekte yönlendiren (referrer) alanı boşsa kullanıcı adresi kendisi yazmıştır. Burası oturumun başlangıcıdır. Bir sonraki yönlendirensiz isteğe kadarki istekler aynı oturumdadır.

Sayfa görüntüleme tanımlama

- Kullanıcı tek bir sayfa ister. Ama tarayıcı sayfadaki her nesne (resim, müzik, diğer çoklu ortam dosyaları) için ayrı HTTP isteği gönderir.
- Kayıt dosyasında tek sayfa için örneğin 10 satır oluşabilir. Bunların tek bir sayfa görüntülemesine (pageview) ait olduğu belirlenmelidir.

Yol tamamlama

- Sitelerin önünde çoğu zaman vekil (proxy) önbellek bulunur. Daha önce istenen sayfaya dönüldüğünde istek sunucuya gitmez, önbellekten karşılanır.
- Hocanın örneği: Kullanıcı A → B → D → E sayfalarına gidiyor. Sonra E'den D'ye, D'den B'ye dönüyor ve B'den C'ye gidiyor.
  - D ve B'ye dönüşler önbellekten karşılandığı için sunucu kaydında yok. Kayıtta E'den sonra doğrudan C görünüyor.
  - Sitenin bağlantı yapısına bakılarak eksik istekler (E→D, D→B) eklenir.

Bölüm (episode) tanımlama

- Oturum içindeki etkinliklerin hangi amaçla yapıldığı bulunur.
  - Örnek amaçlar: satın alma, ürün iade etme, yardım arama, ürün arama, favorilere ekleme.
- İki yol vardır:
  - **Kural tabanlı:** "Kullanıcı şu sayfalara bu sırayla girdiyse ürünü favorilere ekliyordur."
  - **Sınıflandırma:** Sıralı sayfa görüntülemelerinden "satın alma" ya da "almadan terk etme" gibi bir etiket tahmin eden model.
- Hocanın örneğinde kayıtta çok sayıda GET ile arama isteği vardı. Bölüm tanımlamadan sonra davranış şöyle okundu: önce konuma göre arama, sonra konum ve fiyata göre arama, sonra bir ürünü seçme.

Olaylar (events)

- Tıklama akışı verisi her tıklamadır: bağlantı, düğme, onay kutusu.
- Olay birden fazla tıklamanın birleşimi olabilir.
  - Ürün görüntüleme (product view), ürün tıklama (product click-through), sepet değişikliği (shopping cart change), satın alma, ürüne teklif verme.
- Olaylar uygulamanın kendi kayıt dosyasına olay kimliği (event ID) ile yazılabilir. Sayfayı hazırlayan sizsiniz.
- IIS ya da Tomcat gibi sunucuların kayıt dosyası sayfa içinde tanımlanan olayları izleyemez.

Örüntü keşfi ve kullanım alanları

- Veri hazırlandıktan sonra uygulanan teknikler:
  - Birliktelik kuralları: birlikte satılan ürünler. "Birinci ürünü alan şu olasılıkla ikinciyi de alır."
  - Sıralı örüntüler: önce bu ürünü, sonra şu ürünü almak. Ya da önce görüntüleme, sonra satın alma.
  - Kümeleme (clustering): kullanıcıları davranışa göre bölümlere ayırma (segmentation), isteklerden ısı haritaları (heat map), sayfa ve ürün kategorileri.
  - Sınıflandırma: terk etme ya da satın alma tahmini, sahtecilik (fraud) tespiti.
  - Korelasyon analizi: ilişkili ürünleri bulma.
- Bulunan model ve örüntüler filtrelenir, birleştirilir ve pazarlama ya da ilgili iş biriminin önüne konur.
- Hocanın gösterdiği e-ticaret mimarisinde sunucu kayıtları CRM verisiyle bütünleştiriliyor. Ardından veri ambarı (data mart) ve OLAP analizleri ile veri madenciliği kütüphaneleri kullanılıyor.

Ders sonrası notlar

- **HITS ve Yahoo:** Hoca HITS'in Yahoo tarafından kullanıldığını söyledi. HITS'i büyük olasılıkla Jon Kleinberg 1998'de yayımladı. Ticari kullanımda en çok bilinen örnek büyük olasılıkla Teoma arama motorudur (sonra Ask.com). Yahoo'nun HITS kullandığına dair yaygın bir kaynak büyük olasılıkla yoktur.
- **Kök küme, taban küme:** Hoca bir yerde ilk bulunan URL'lere "base set" dedi. Doğrusu: sorguyla eşleşen ilk küme kök kümedir (root set). Bir adım ileri ve geri genişletilmiş küme taban kümedir (base set).
- **Merkez denklemi:** Hoca bir yerde h için "komşuluk matrisinin transpozesi çarpı hub vektörü" dedi. Doğrusu $h = L\,L^T h$'dir; yalnız $L^T h$ otorite vektörünü verir. Küçük bir test grafında python ile yapılan kontrolde $h = L\,L^T h$ yinelemesi merkez skorlarına, $L^T h$ yinelemesi ise farklı bir vektöre yakınsadı.
- **Normalleştirme:** HITS'te her yinelemeden sonra a ve h vektörleri normalize edilir. Yoksa değerler sürekli büyür. Derste bu adımdan söz edilmedi. Python ile küçük bir test grafında normalleştirmesiz yinelemede değerlerin 10 adımda yüz binlere çıktığı, normalleştirmeli yinelemenin ise $L^T L$ ve $L\,L^T$ matrislerinin baskın özvektörlerine yakınsadığı doğrulandı.
- **"HREF alanı":** Hoca, isteğin hangi sayfadan geldiğini gösteren alanı bir yerde "HREF" diye andı. Doğrusu HTTP isteğindeki `Referer` başlığıdır.
- **Gezinmeye dayalı sezgi:** Kitaptaki referrer tabanlı sezgi (h-ref) büyük olasılıkla şöyle tanımlanır: Bir isteğin yönlendireni o anki oturumda daha önce görüntülenmiş bir sayfaysa, istek o oturuma eklenir. Değilse yeni oturum başlar. Hocanın anlattığı "yönlendiren boşsa yeni oturum" kuralı bunun özel bir durumudur. Ayrıca kitapta büyük olasılıkla yönlendiren boş bırakılan isteklerin de oturuma eklenebileceği belirtilir.
- **Zaman sezgisinde "en az 3 sayfa":** Hoca 30 dakika ve sayfa başına 10 dakika sınırından "en az 3 sayfa" sonucunu çıkarmaya çalıştı, sonra düzeltti. İki sınır birbirinden bağımsızdır. Sayfa sayısı için bir alt sınır yoktur.
- **Kaynak:** Bölüm numaraları Bing Liu'nun *Web Data Mining* kitabıyla uyumludur. 12. bölüm (Web Usage Mining) büyük olasılıkla Bamshad Mobasher tarafından yazılmıştır.

Not: İsterseniz bu dersin altyazı (.srt) dosyasını Gemini Notebook gibi bir yapay zeka aracına yükleyerek ders hakkında daha detaylı soru-cevaplar yapabilir ve dersi verimli çalışabilirsiniz.